Введение в дисциплину «Анализ и прогнозирование временных рядов методами искусственного интеллекта»

https://mzym.susu.ru/courses/tsm/



Невольно изречешь: **o tempora, o mores!** —
Когда поразглядишь, какая в жизни горесть.

Н.А. Некрасов

Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- Основные задачи анализа временных рядов
- Определения и нотация

Люди измеряют всевозможные вещи, изменяющиеся во времени

- ЭКГ, пульс, давление, калории
- Рождаемость и смертность
- Температура и влажность воздуха
- Расход электричества и воды
- Рейтинг популярности политиков
- Спортивная статистика
- Клики веб-страниц
- Курсы валют и акций
- ВВП и госдолг
- …

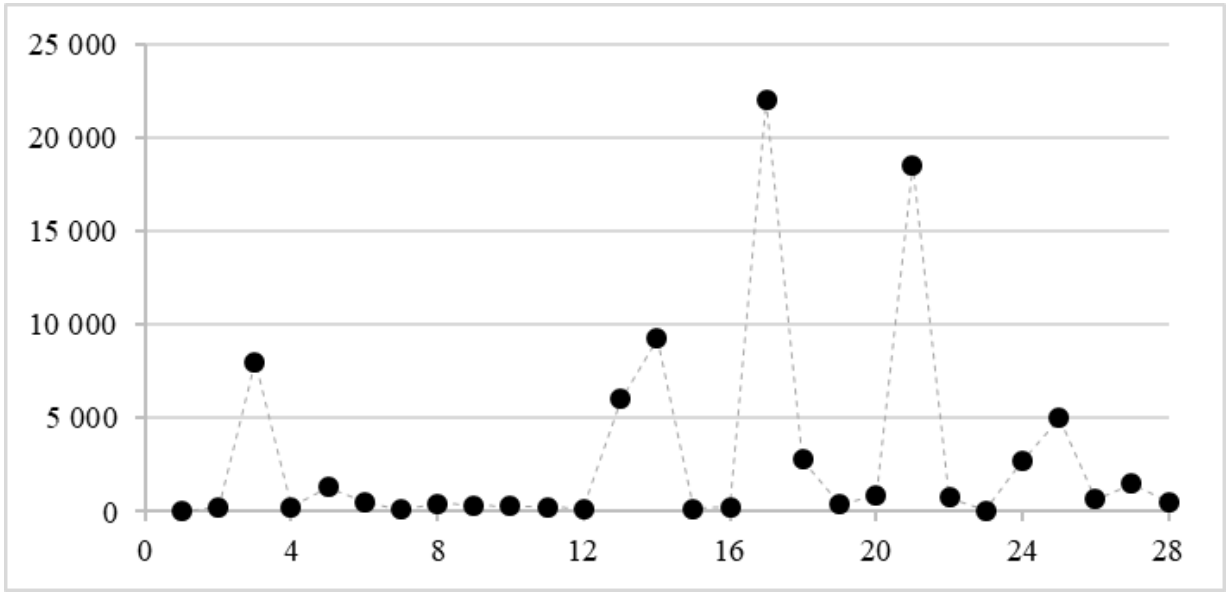
Временной ряд – хронологически упорядоченная последовательность чисел

Временной ряд ≠ сигнал (функция)

Временной ряд

$$T = (t_1, \dots, t_n)$$

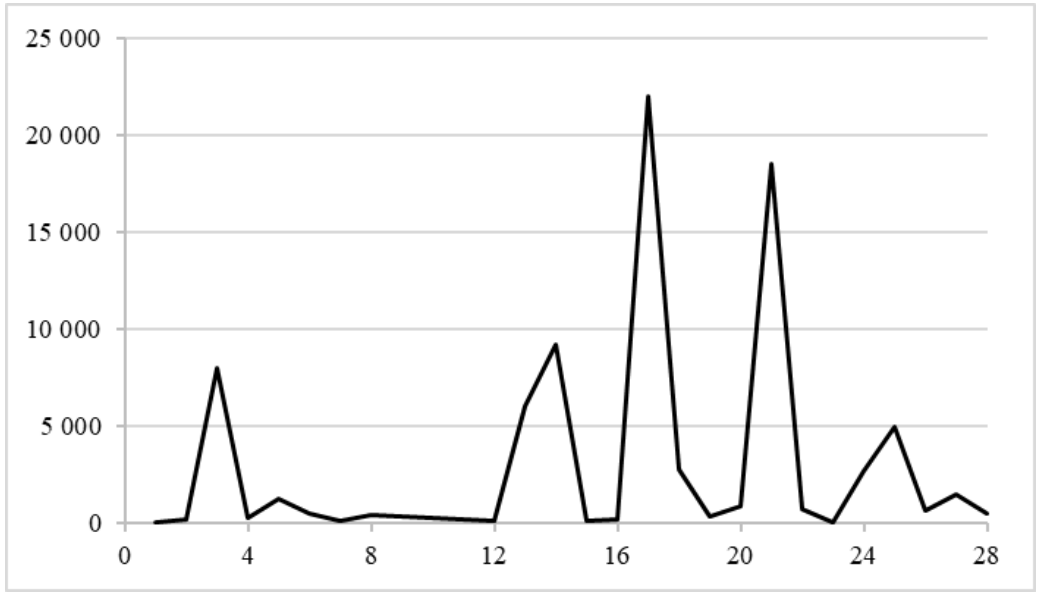
$$\forall i \in \mathbb{N}, 1 \le i \le n\colon \exists\, t_i \in \mathbb{R}$$



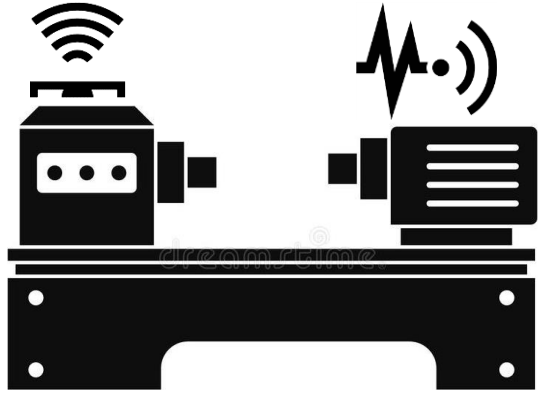
Сигнал (функция)

$$T\colon \operatorname{dom} T \to \mathbb{R}$$

$$\forall t \in \operatorname{dom} T\colon \exists\, T(t) \in \mathbb{R}$$



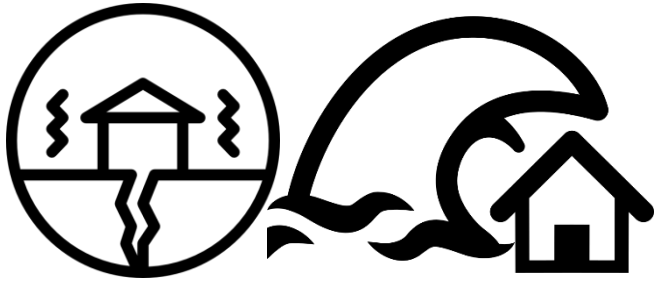
Временные ряды везде…



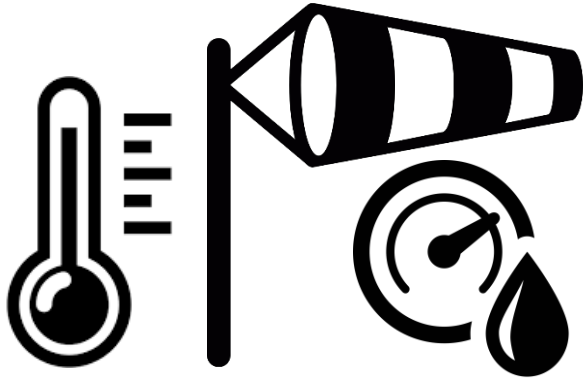
Умное производство, предиктивное ТО



Интернет вещей



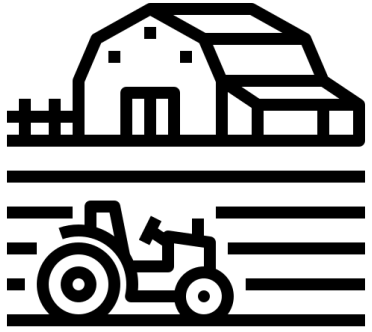
Предсказание природных катаклизмов



Прогноз погоды, моделирование климата



Персональная медицина



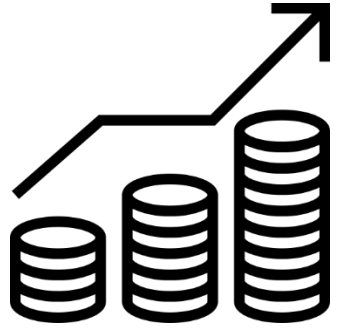
Сельское хоз-во, животноводство



Борьба с преступностью



Био- и хемо-информатика



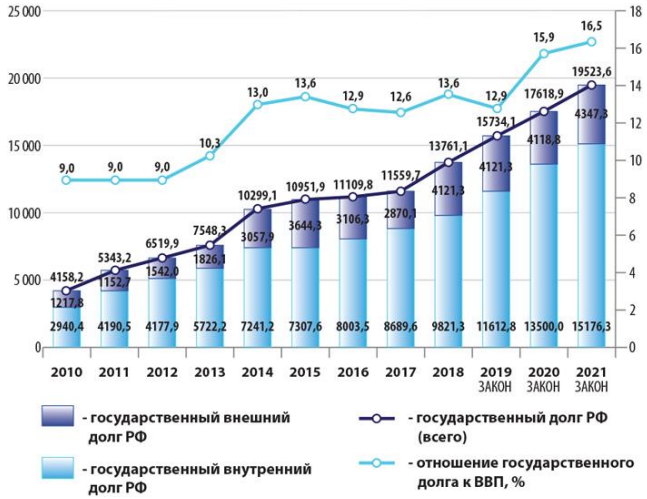
Экономика, бизнес, финансы



Системы электронного обучения

… и всюду





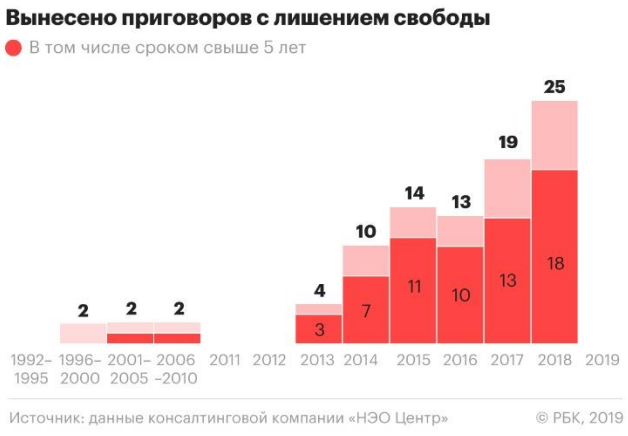
Случайная выборка из 4000 изображений в 15 газетах из различных стран за 1974–1989 гг.: **более 75% изображений – это временные ряды**

Tufte E. The Visual Display of Quantitative Information. Graphics Press, 2001. 200 p.



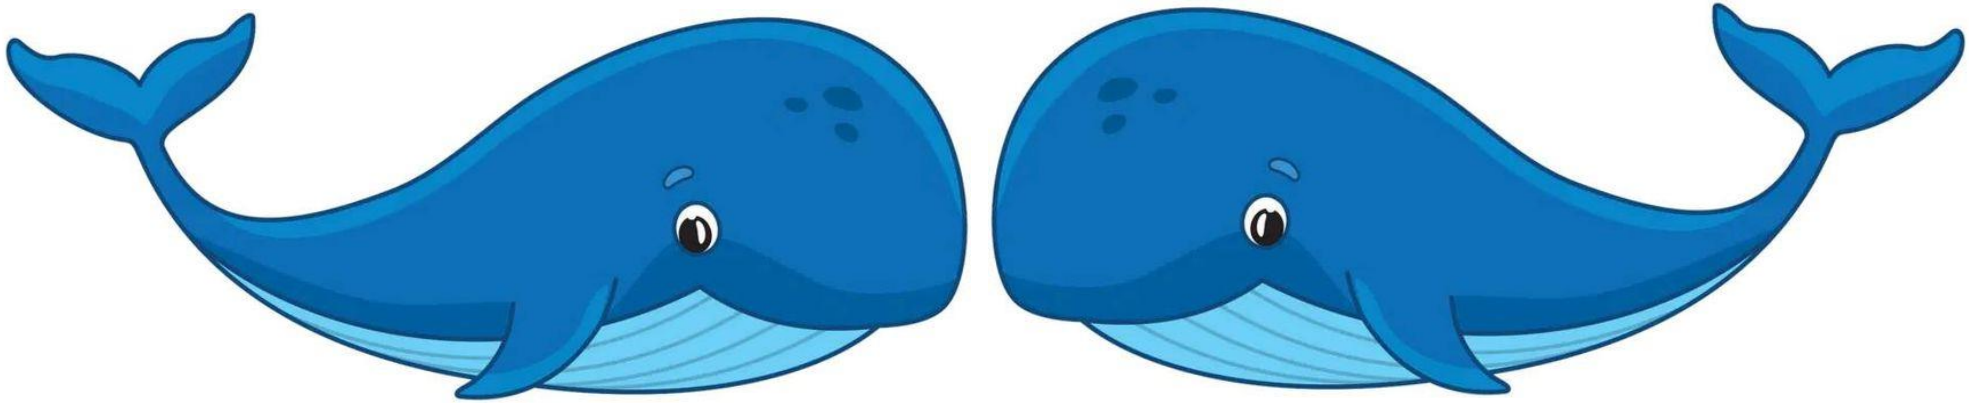






Предмет дисциплины

Интеллектуальная обработка временных рядов



Интеллектуальный анализ
(time series mining)
Паттерны и аномалии
Почему это происходило в прошлом и настоящем?

1-я часть курса

Анализ и прогноз
(time series analysis)
Математические модели
Что произойдет в будущем?

2-я часть курса

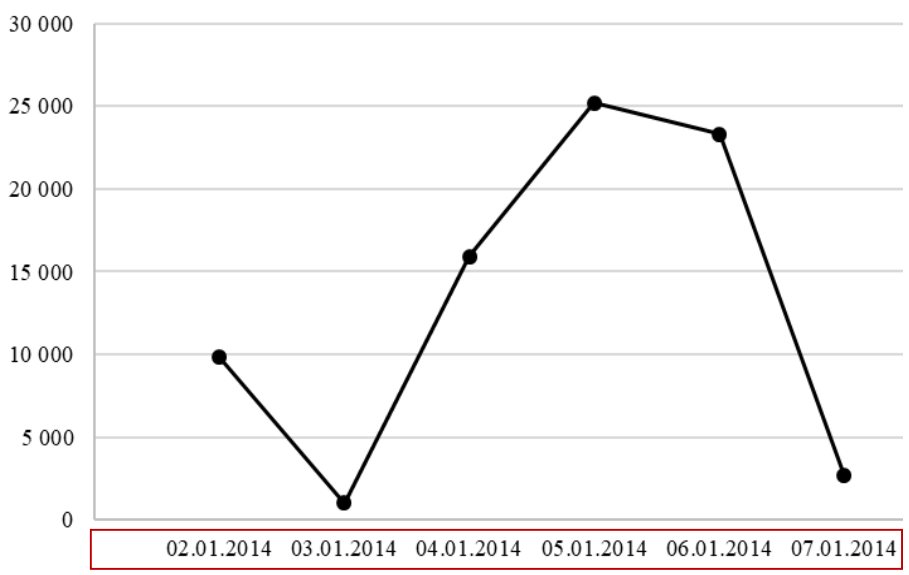
Содержание

- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

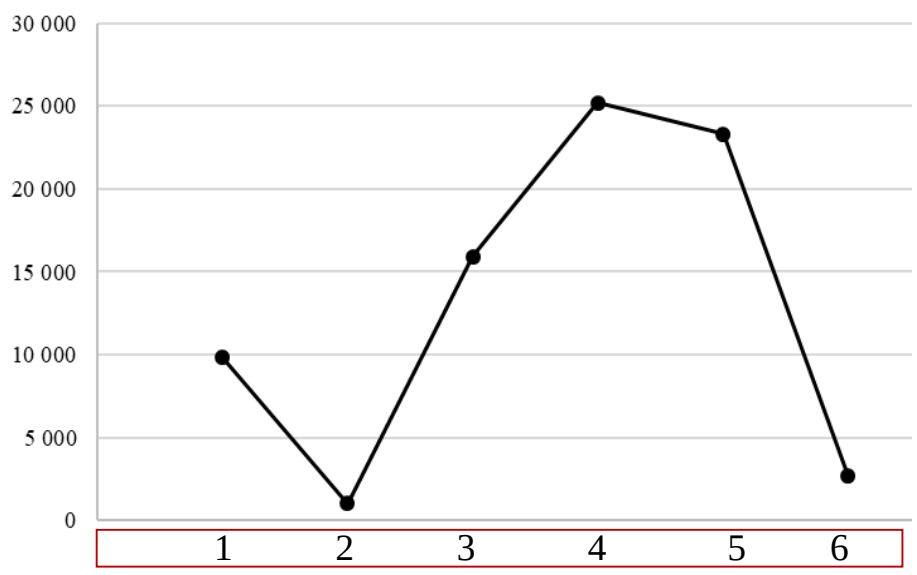
Фиксированная частота измерений

- Точки (элементы) ряда ассоциированы с временны*ы*ми метками, сделанными через **равные промежутки** (т.е. частота измерений фиксирована)
- Значения временны*ы*х меток могут не подвергаться обработке или отсутствовать в исходных данных

	Отметка времени	Значение
1	02.01.2014	9810
2	03.01.2014	1037
3	04.01.2014	15912
4	05.01.2014	25180
5	06.01.2014	23307
6	07.01.2014	2680

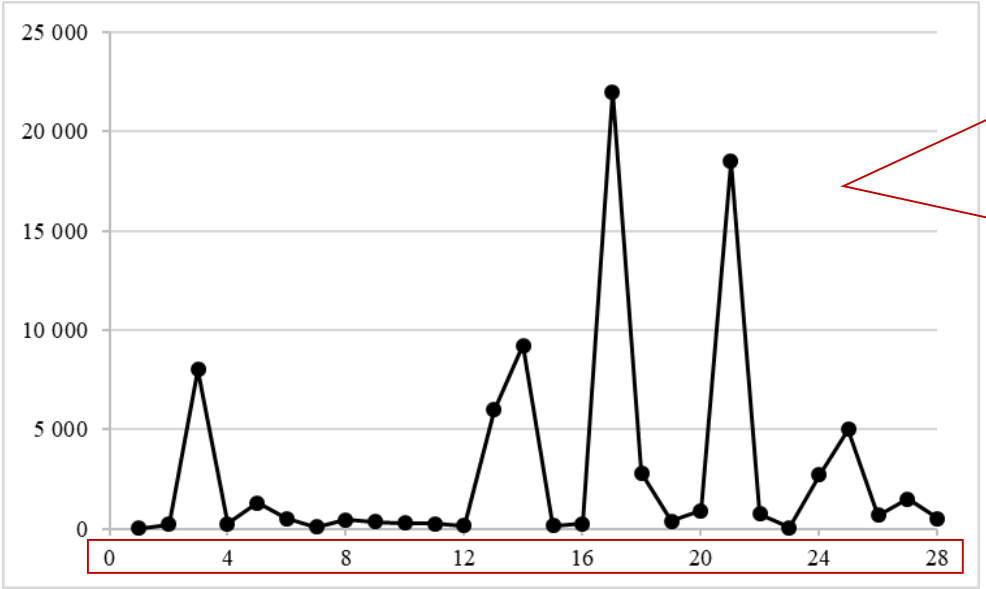


	Значение
1	9810
2	1037
3	15912
4	25180
5	23307
6	2680



Важность фиксированной частоты измерений

№	Отметка времени	Значение
1	02.01.2014 07:29	30
2	02.01.2014 16:05	230
3	02.01.2014 16:17	8000
4	02.01.2014 18:15	250
5	02.01.2014 19:22	1300
6	03.01.2014 08:27	500
7	03.01.2014 09:18	100
8	03.01.2014 10:58	437
9	04.01.2014 04:22	350
10	04.01.2014 09:58	280
11	04.01.2014 12:44	240
12	04.01.2014 18:25	160
13	04.01.2014 20:26	6000
14	04.01.2014 21:33	9232
15	05.01.2014 06:22	140
16	05.01.2014 14:17	240
17	05.01.2014 14:48	22000
18	05.01.2014 16:11	2800
19	06.01.2014 09:43	377
20	06.01.2014 12:00	910
21	06.01.2014 14:14	18500
22	06.01.2014 15:50	750
23	06.01.2014 16:12	70
24	06.01.2014 21:05	2700
25	07.01.2014 15:33	5000
26	07.01.2014 16:17	680
27	07.01.2014 18:11	1500
28	07.01.2014 22:03	500



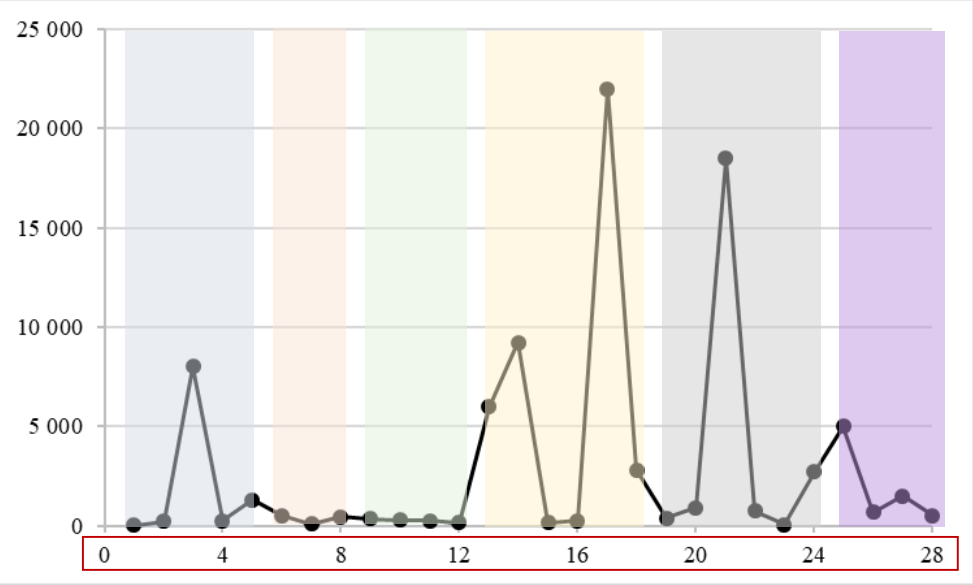
Обработка данных
не имеет смысла
(**ЭТО НЕ ВРЕМЕННОЙ РЯД**),
т.к. измерения сделаны через
разные
промежутки времени

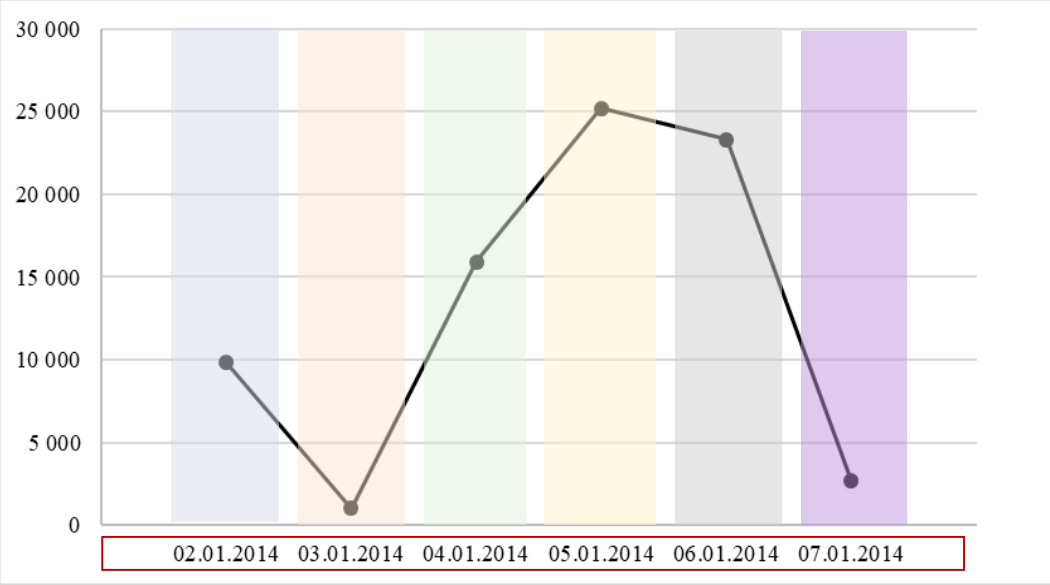
Важность фиксированной частоты измерений

№	Отметка времени	Значение
1	02.01.2014 07:29	30
2	02.01.2014 16:05	230
3	02.01.2014 16:17	8000
4	02.01.2014 18:15	250
5	02.01.2014 19:22	1300
6	03.01.2014 08:27	500
7	03.01.2014 09:18	100
8	03.01.2014 10:58	437
9	04.01.2014 04:22	350
10	04.01.2014 09:58	280
11	04.01.2014 12:44	240
12	04.01.2014 18:25	160
13	04.01.2014 20:26	6000
14	04.01.2014 21:33	9232
15	05.01.2014 06:22	140
16	05.01.2014 14:17	240
17	05.01.2014 14:48	22000
18	05.01.2014 16:11	2800
19	06.01.2014 09:43	377
20	06.01.2014 12:00	910
21	06.01.2014 14:14	18500
22	06.01.2014 15:50	750
23	06.01.2014 16:12	70
24	06.01.2014 21:05	2700
25	07.01.2014 15:33	5000
26	07.01.2014 16:17	680
27	07.01.2014 18:11	1500
28	07.01.2014 22:03	500

Агрегация с помощью суммирования

№	Отметка времени	Значение
1	02.01.2014	9810
2	03.01.2014	1037
3	04.01.2014	15912
4	05.01.2014	25180
5	06.01.2014	23307
6	07.01.2014	2680



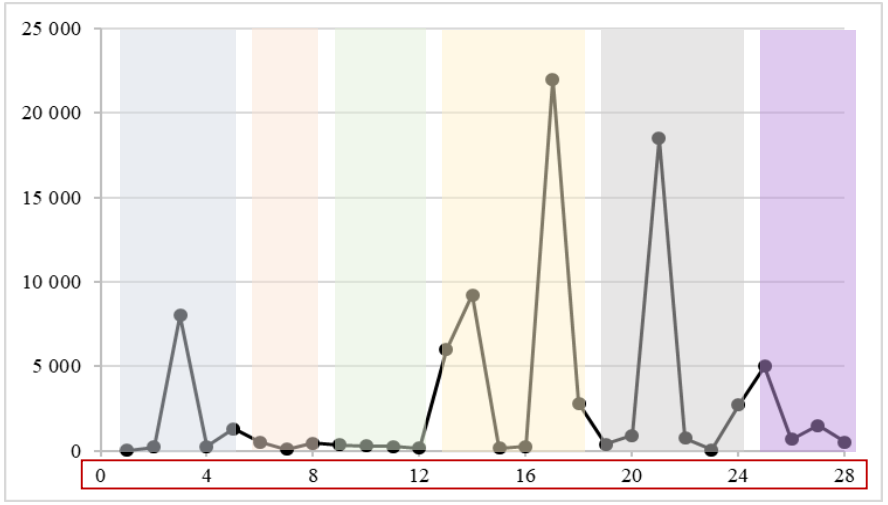


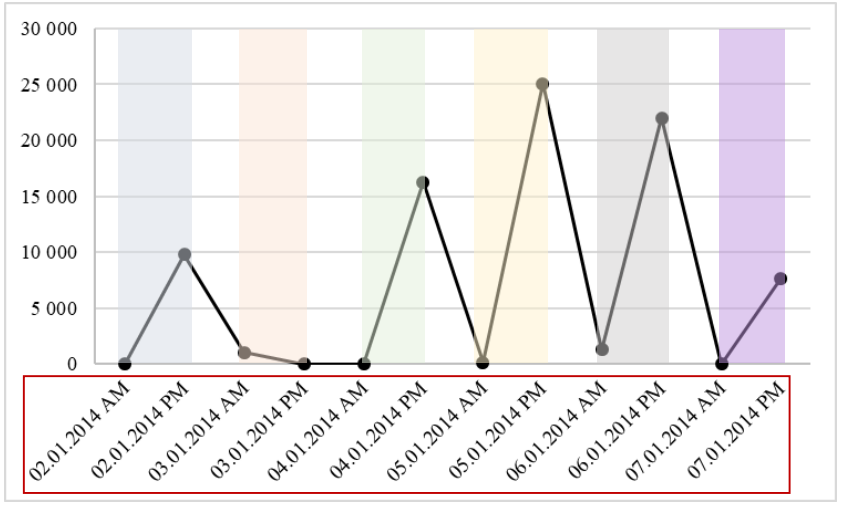
Важность фиксированной частоты измерений

№	Отметка времени	Значение
1	02.01.2014 07:29	30
2	02.01.2014 16:05	230
3	02.01.2014 16:17	8000
4	02.01.2014 18:15	250
5	02.01.2014 19:22	1300
6	03.01.2014 08:27	500
7	03.01.2014 09:18	100
8	03.01.2014 10:58	437
9	04.01.2014 04:22	350
10	04.01.2014 09:58	280
11	04.01.2014 12:44	240
12	04.01.2014 18:25	160
13	04.01.2014 20:26	6000
14	04.01.2014 21:33	9232
15	05.01.2014 06:22	140
16	05.01.2014 14:17	240
17	05.01.2014 14:48	22000
18	05.01.2014 16:11	2800
19	06.01.2014 09:43	377
20	06.01.2014 12:00	910
21	06.01.2014 14:14	18500
22	06.01.2014 15:50	750
23	06.01.2014 16:12	70
24	06.01.2014 21:05	2700
25	07.01.2014 15:33	5000
26	07.01.2014 16:17	680
27	07.01.2014 18:11	1500
28	07.01.2014 22:03	500

Агрегация с помощью суммирования

№	Отметка времени	Значение
1	02.01.2014 AM	30
2	02.01.2014 PM	9780
3	03.01.2014 AM	1037
4	03.01.2014 PM	0
5	04.01.2014 AM	0
6	04.01.2014 PM	16262
7	05.01.2014 AM	140
8	05.01.2014 PM	25040
9	06.01.2014 AM	1287
10	06.01.2014 PM	22020
11	07.01.2014 AM	0
12	07.01.2014 PM	7680

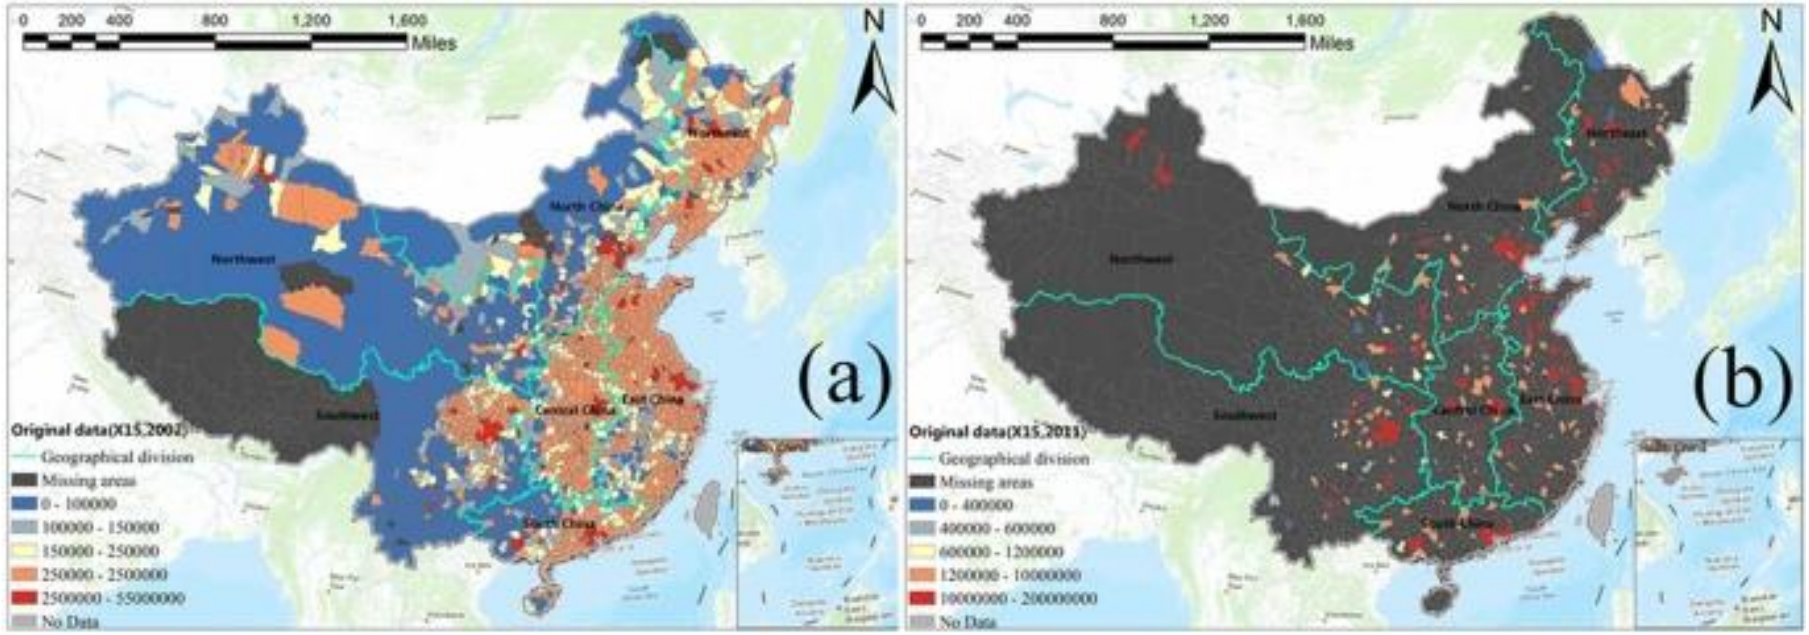




Содержание

- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

Пропущенные значения во временных рядах (NULL/NaN)



Доля провинций Китая, **не** предоставившие данные *по одному атрибуту* для гос. стат. отчета*

a) 2002: менее 15%
b) 2011: более 85%

* Song C. *et al*. Estimating missing values in China's official socioeconomic statistics using progressive spatiotemporal Bayesian hierarchical modeling. Sci. Rep. 2018. Vol. 8, article 10055. DOI: 10.1038/s41598-018-28322-z

Содержание

- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

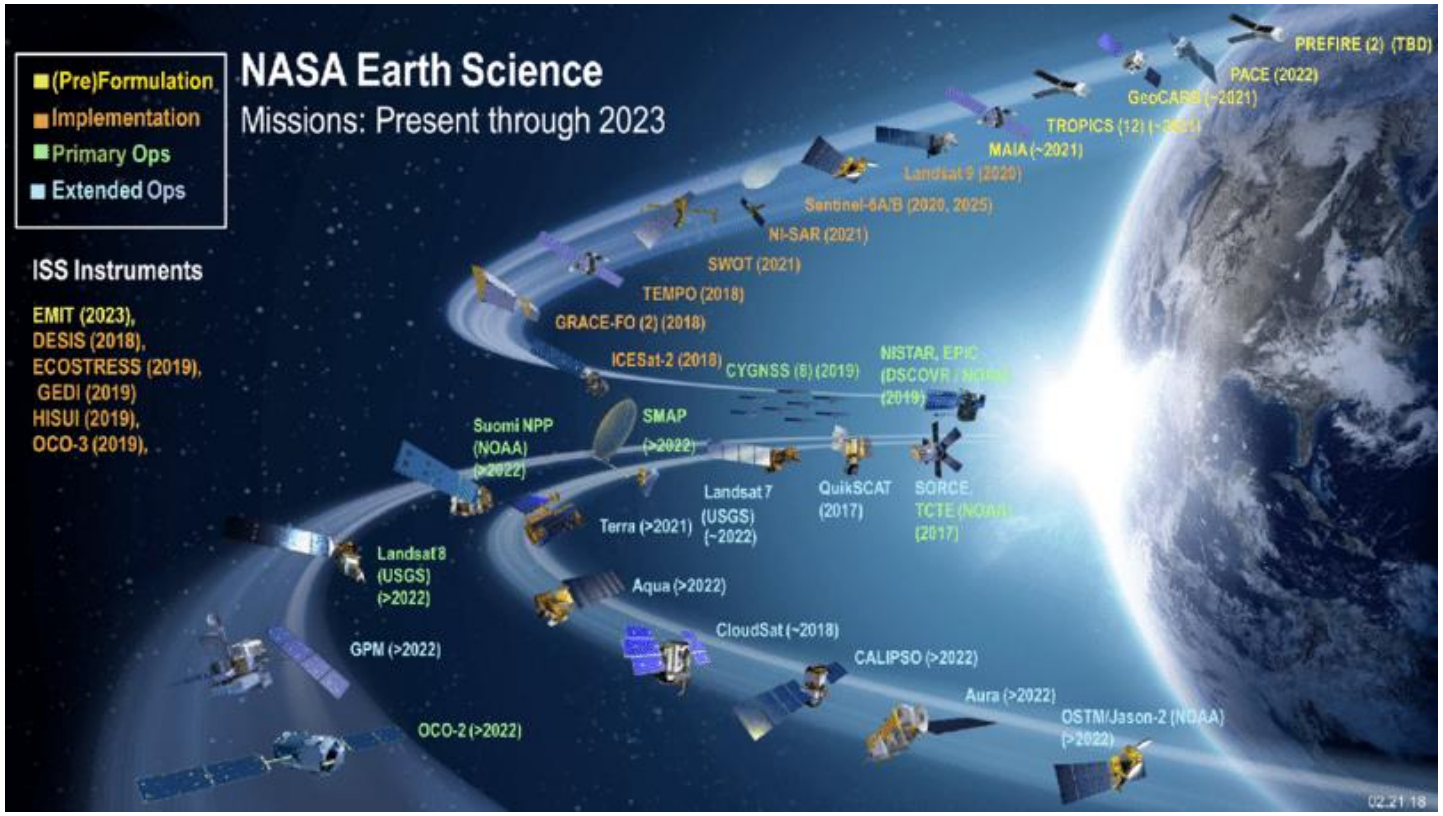
Большие временные ряды: AEMO Solar



Оборудование **AEMO (Australian Energy Market Operator)** регистрирует выработку солнечной энергии (МВт) в Австралии с 2019 г. каждые 4 с

https://zenodo.org/record/4656027

Большие временные ряды: Earth Observations Database



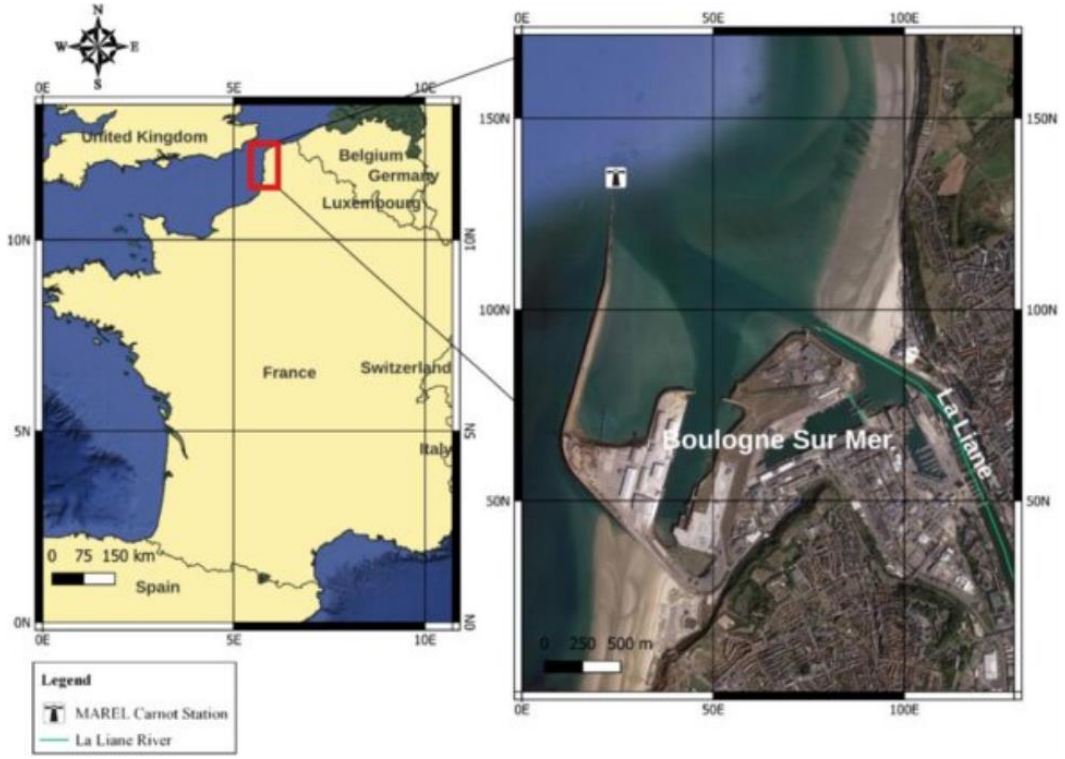
Размер [NASA Space Shuttle Earth Observations Database](#) – 40 Пб* (2020 г.), ожидаемый далее ежегодный прирост 50 Пб

* 1 Петабайт=10^{15} (квадриллион) байт, 10^{15} ≈ к-во синапсов в головном мозге человека

https://www.nasa.gov/feature/goddard/2020/nasa-funds-projects-to-make-geosciences-data-more-accessible

Большие временные ряды: MAREL Carnot





Океанографическая станция **MAREL (Mesures Automatisées en Réseau pour l'Environnement Littoral, automated sampling network for coastal waters) Carnot** с 2004 г. регистрирует каждые 20 мин. более чем 15 химических и биологических характеристик воды в проливе Ла-Манш

Ben Ismail D.K. *et al.* Statistical properties and time-frequency analysis of temperature, salinity and turbidity measured by the MAREL Carnot station in the coastal waters of Boulogne-sur-Mer (France). Journal of Marine Systems. 2016. Vol. 162. P. 137-153. https://doi.org/10.1016/j.jmarsys.2016.03.010

Большие временные ряды: DEBS Challenge



Набор данных **DEBS (Distributed and Event-Based Systems) Challenge 2013**: сенсоры пространственного позиционирования закреплены на бутсах игроков и перчатках вратаря (200 Гц), а также на мяче (2000 Гц), всего 15K событий в секунду

Mutschler C. *et al.* The DEBS 2013 grand challenge. DEBS'13: Proc. of the 7th ACM international conference on Distributed event-based systems. 2013. P. 289–294. https://doi.org/10.1145/2488222.2488283

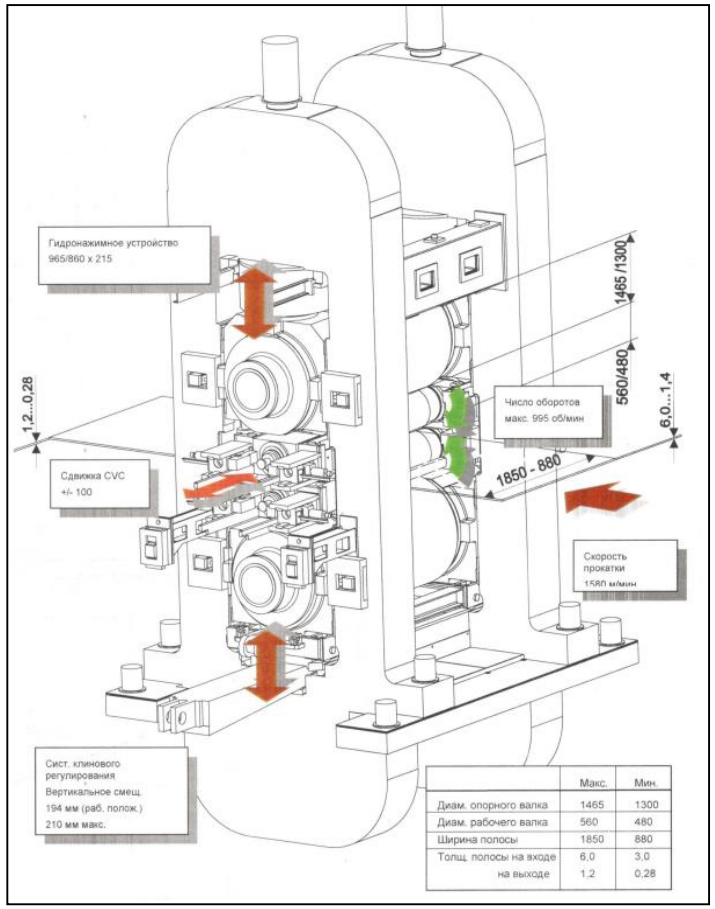
Большие временные ряды: Madrid VAR

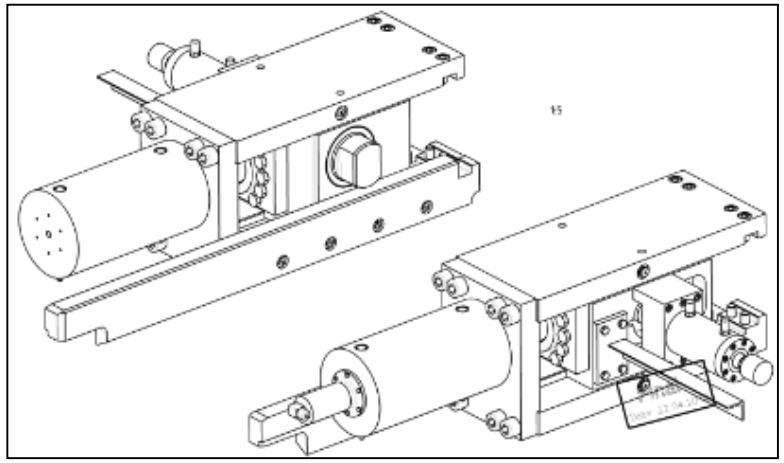


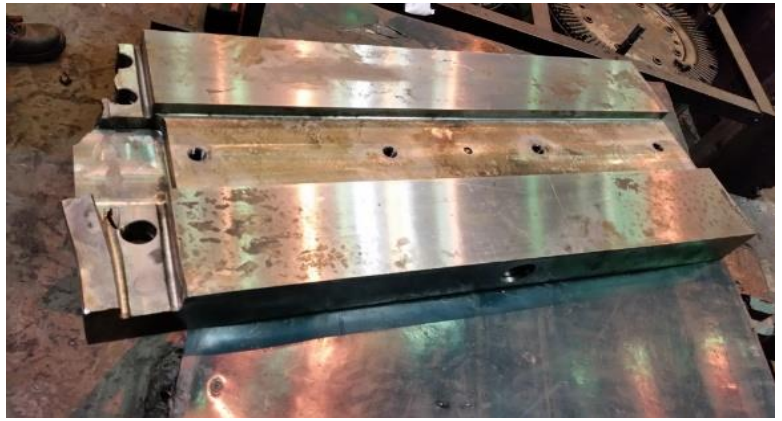
Система контроля дорожного движения в Мадриде насчитывает более 3500 автоматических регистраторов транспортных средств (VAR, Vehicle Automatic Registrar), выдающих показания каждые 15 мин., начиная с 2014 г.

Laña I. *et al.* On the imputation of missing data for road traffic forecasting: New insights and novel techniques. Transportation Research Part C: Emerging Technologies. 2018. Vol. 90. pp. 18-33. DOI: 10.1016/j.trc.2018.02.021

Большие временные ряды: система профилировки валков прокатного стана









CVC (Continuously Variable Curvature)-система стана холодной прокатки Магнитогорского металлургического комбината насчитывает более 100 датчиков с частотой 1 Гц.

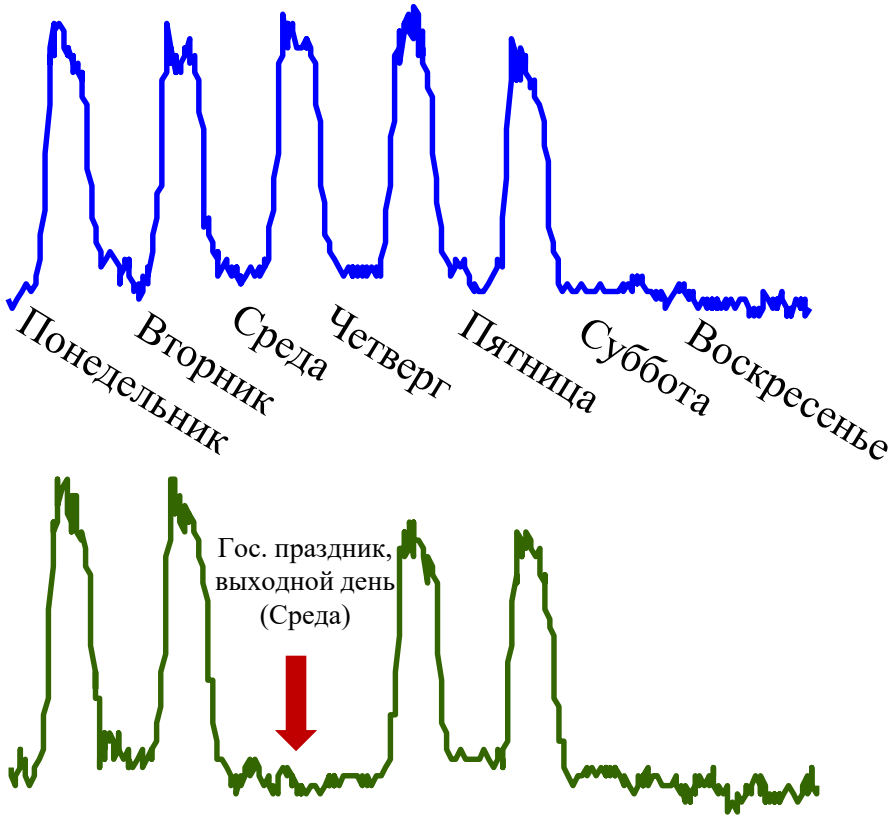
Краева Я.А. Поиск аномалий в сенсорных данных цифровой индустрии с помощью параллельных вычислений. Вестник ЮУрГУ. Серия: Вычислительная математика и информатика. 2023. Т. 12, № 2. С. 47–61.https://doi.org/10.14529/cmse230202

Содержание

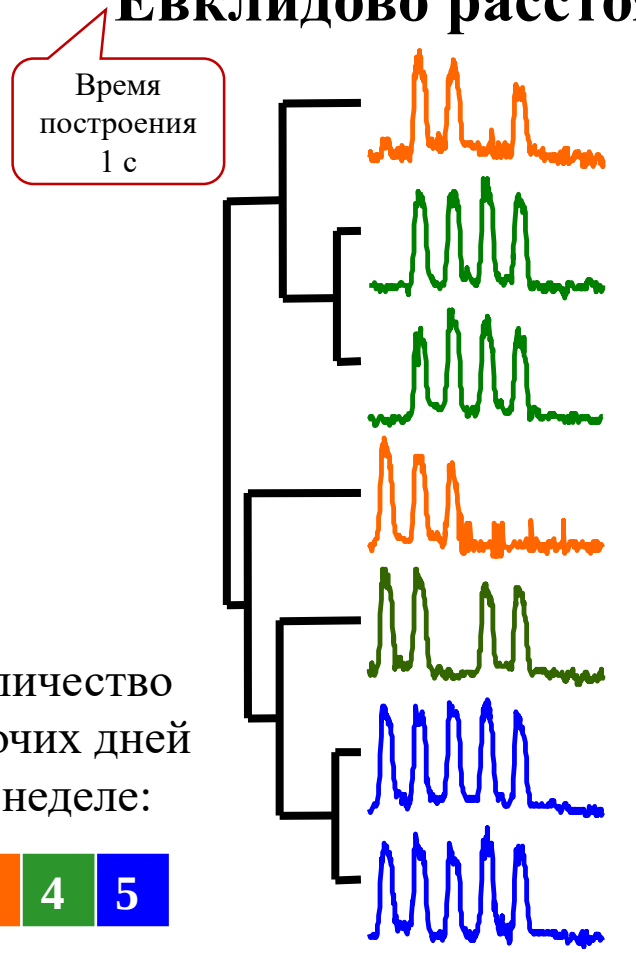
- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

Предметная область и задача определяют функцию расстояния

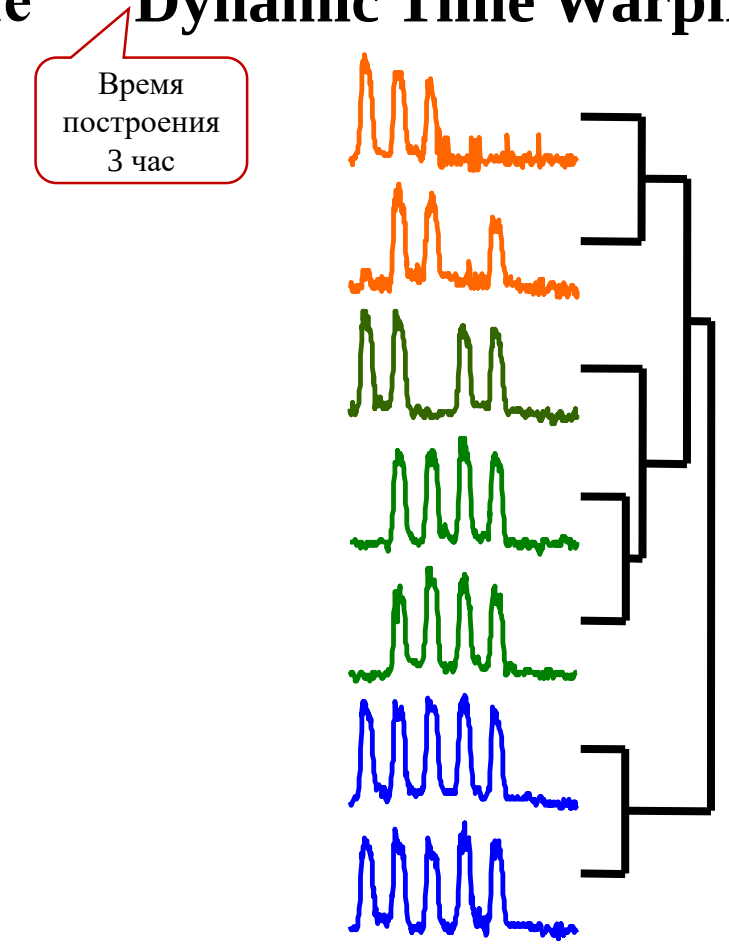
Недельное энергопотребление вычислительного центра (Голландия, 1997)*



Евклидово расстояние



Dynamic Time Warping



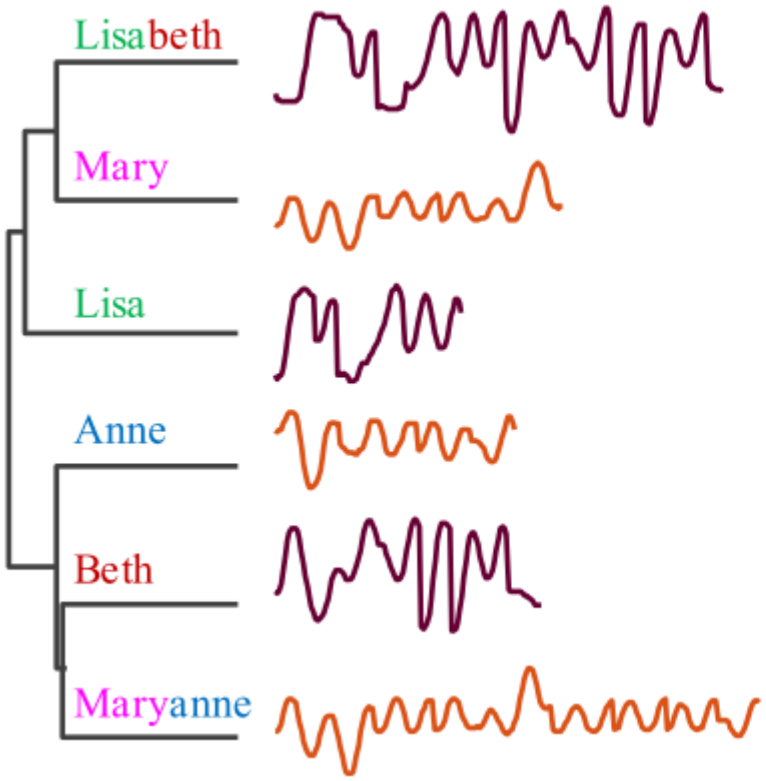
Количество рабочих дней в неделе:

3 4 5

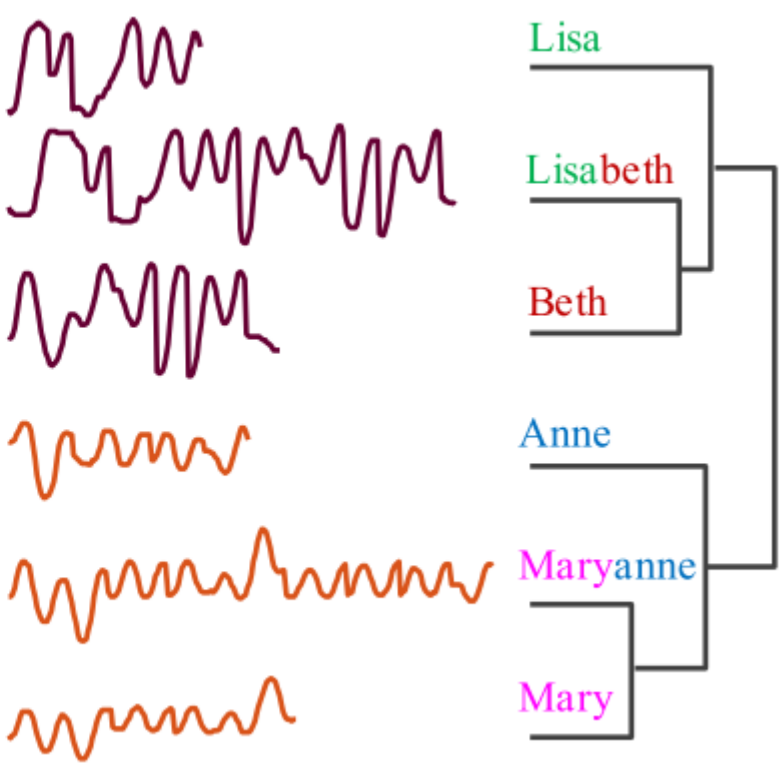
* van Wijk J.J., van Selow R.R. Cluster and calendar based visualization of time series data. INFOVIS 1999: 4-9. DOI: 10.1109/INFVIS.1999.801851

Предметная область и задача определяют функцию расстояния

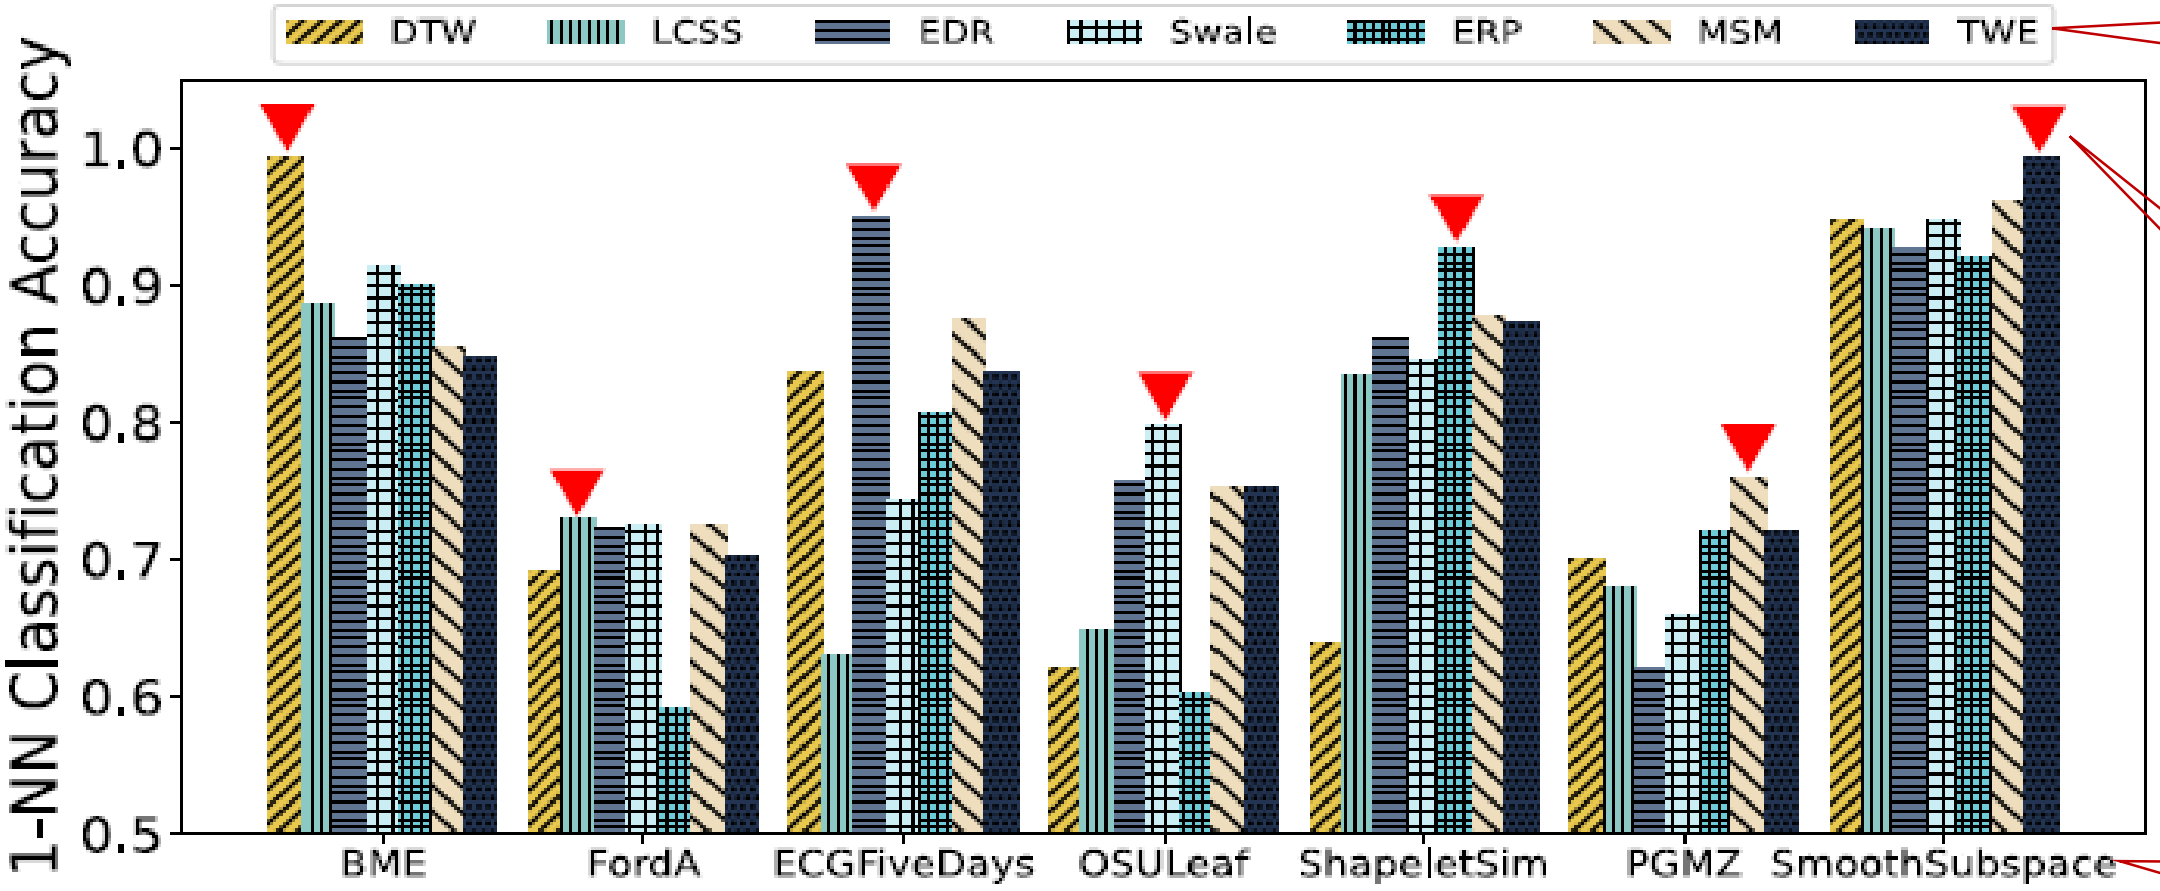
Евклидово расстояние



Расстояние MPdist



Предметная область и задача определяют функцию расстояния



Функции расстояния

Лучшие результаты

Наборы данных

Paparrizos, J. *et al.* Accelerating similarity search for elastic measures: A study and new generalization of lower bounding distances. Proc. VLDB Endow. 16(8), 2019–2032 (2023). DOI 10.14778/3594512.3594530. https://www.vldb.org/pvldb/vol16/p2019-paparrizos.pdf

Содержание

- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

Шумы во временных рядах

- *Шум (noise)* – случайные, нежелательные колебания, которые маскируют полезный сигнал;
  - высокочастотные, мелкомасштабные флуктуации, распределенные по всему ряду и не несущие смысловой нагрузки
  - возникают ввиду погрешностей измерения, внешних воздействий на систему и др.
- Аномалии ≠ шум –редкие, значимые отклонения от ожидаемого поведения, которые могут указывать на сбои, качественные изменения в системе и др.

Содержание

- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

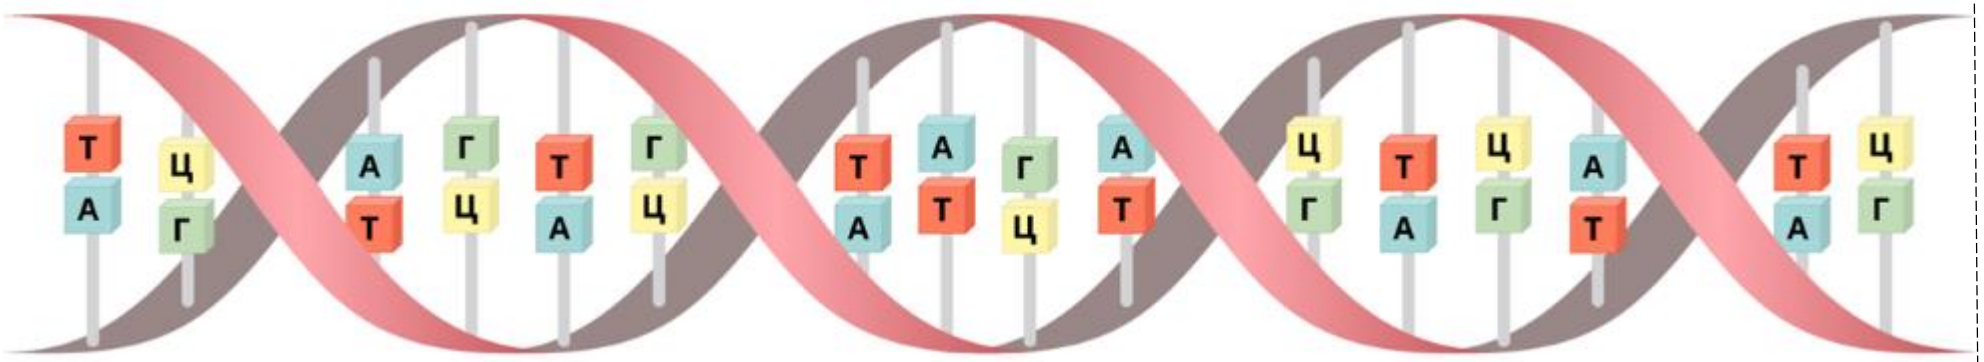
Форматы хранения данных временных рядов

- Текстовые, финансовые данные
  - **CSV** (Comma-Separated Values), **TSV** (Tab-Separated Values)
  - JSON (JavaScript Object Notation)
- Аудио данные
  - MP3 – сжатие с потерями
  - WAV – несжатый сигнал
- Научные данные
  - HDF (Hierarchical Data Format) – многомерные данные
- …

Содержание

- Объект и предмет дисциплины
- **Ключевые особенности интеллектуальной обработки временных рядов**
  - Фиксированная частота измерений
  - Пропущенные значения
  - Большой объем
  - Важность функции расстояния
  - Шумы
  - Различные форматы данных
  - Трансформация данных иной природы во временной ряд
- Основные задачи интеллектуального анализа временных рядов
- Определения и нотация

ДНК как временной ряд

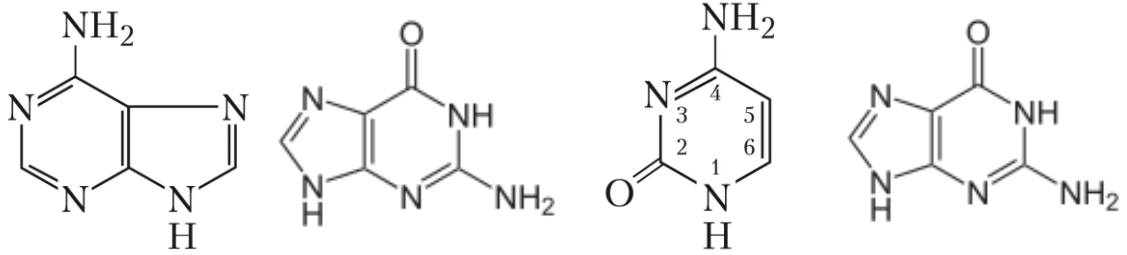


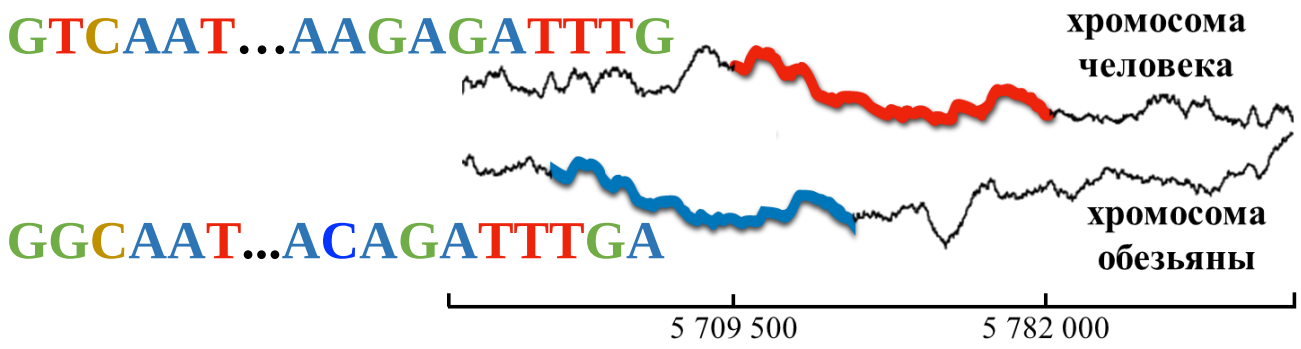
ДНК (дезоксирибонуклеиновая кислота) – макромолекула, обеспечивающая хранение, передачу через поколения и реализацию генетической программы развития и функционирования организмов

Трансформация ДНК во временной ряд

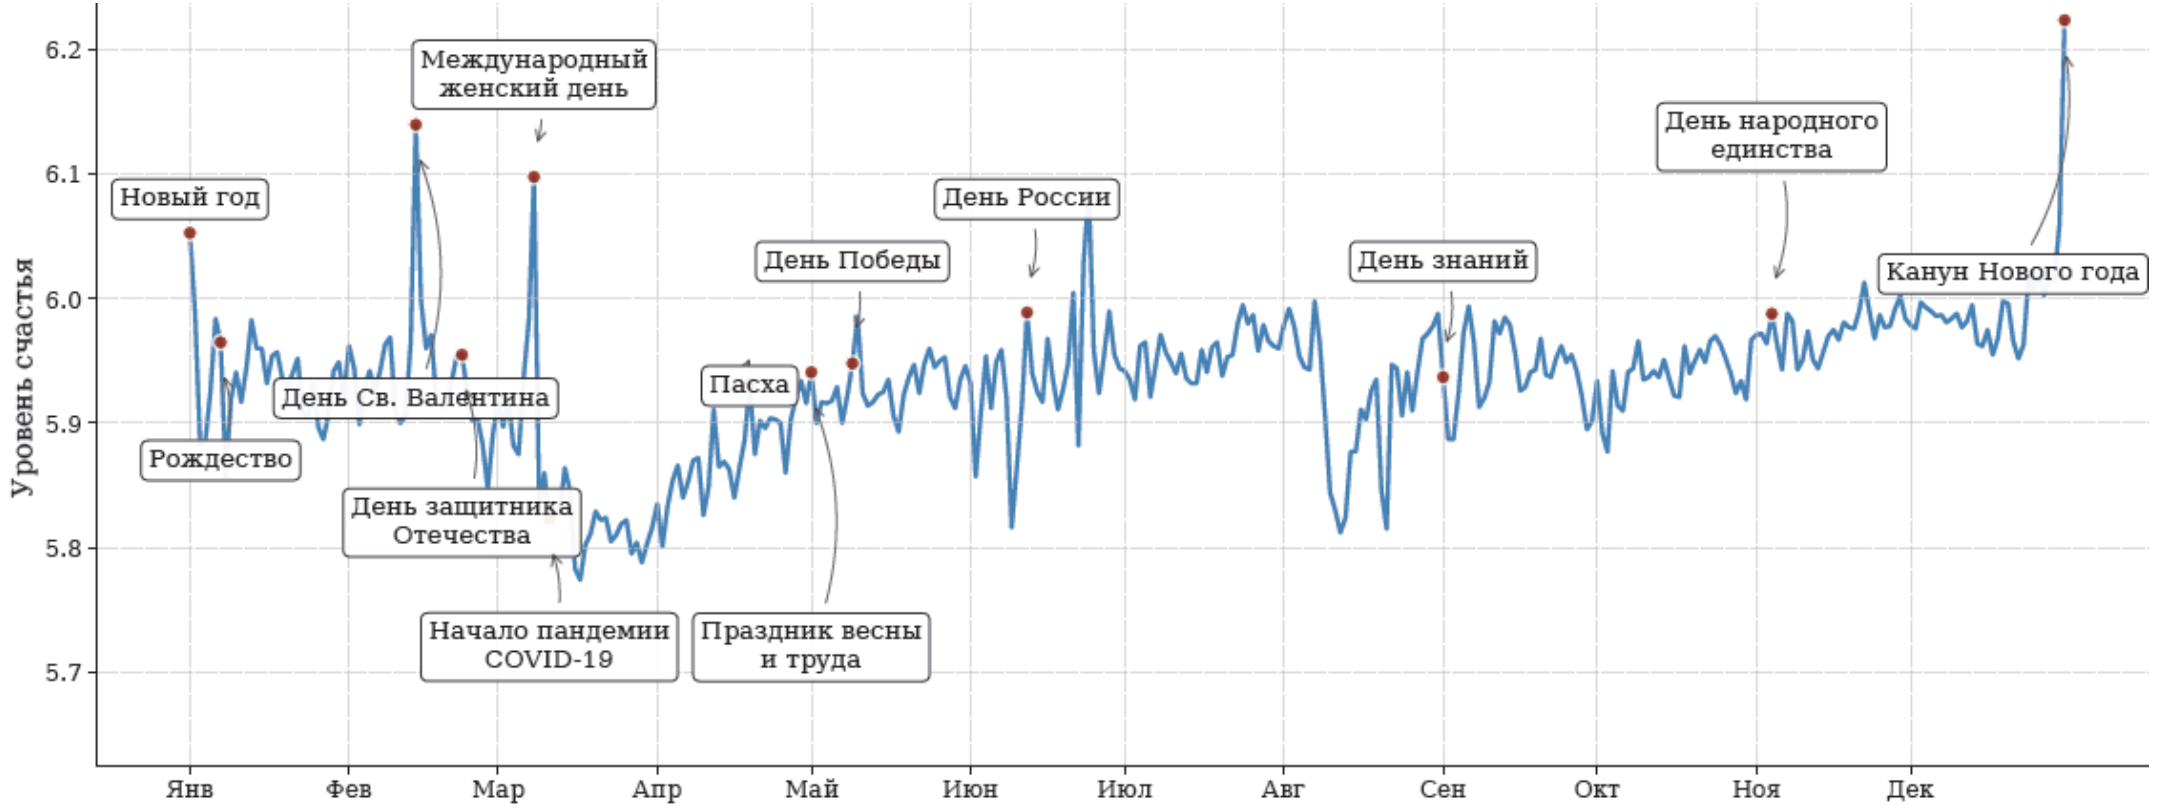
$t_1 := 0$
for $i \in 1..|DNA|$ **do**
  case $DNA[i]$ **of**
  A : $t_{i+1} := t_{i+2}$
  G : $t_{i+1} := t_{i+1}$
  C : $t_{i+1} := t_{i-1}$
  T : $t_{i+1} := t_{i-2}$
  end

А (Adenine)	**Т** (Thymine)	**Ц** (Cytosine)	**Г** (Guanine)



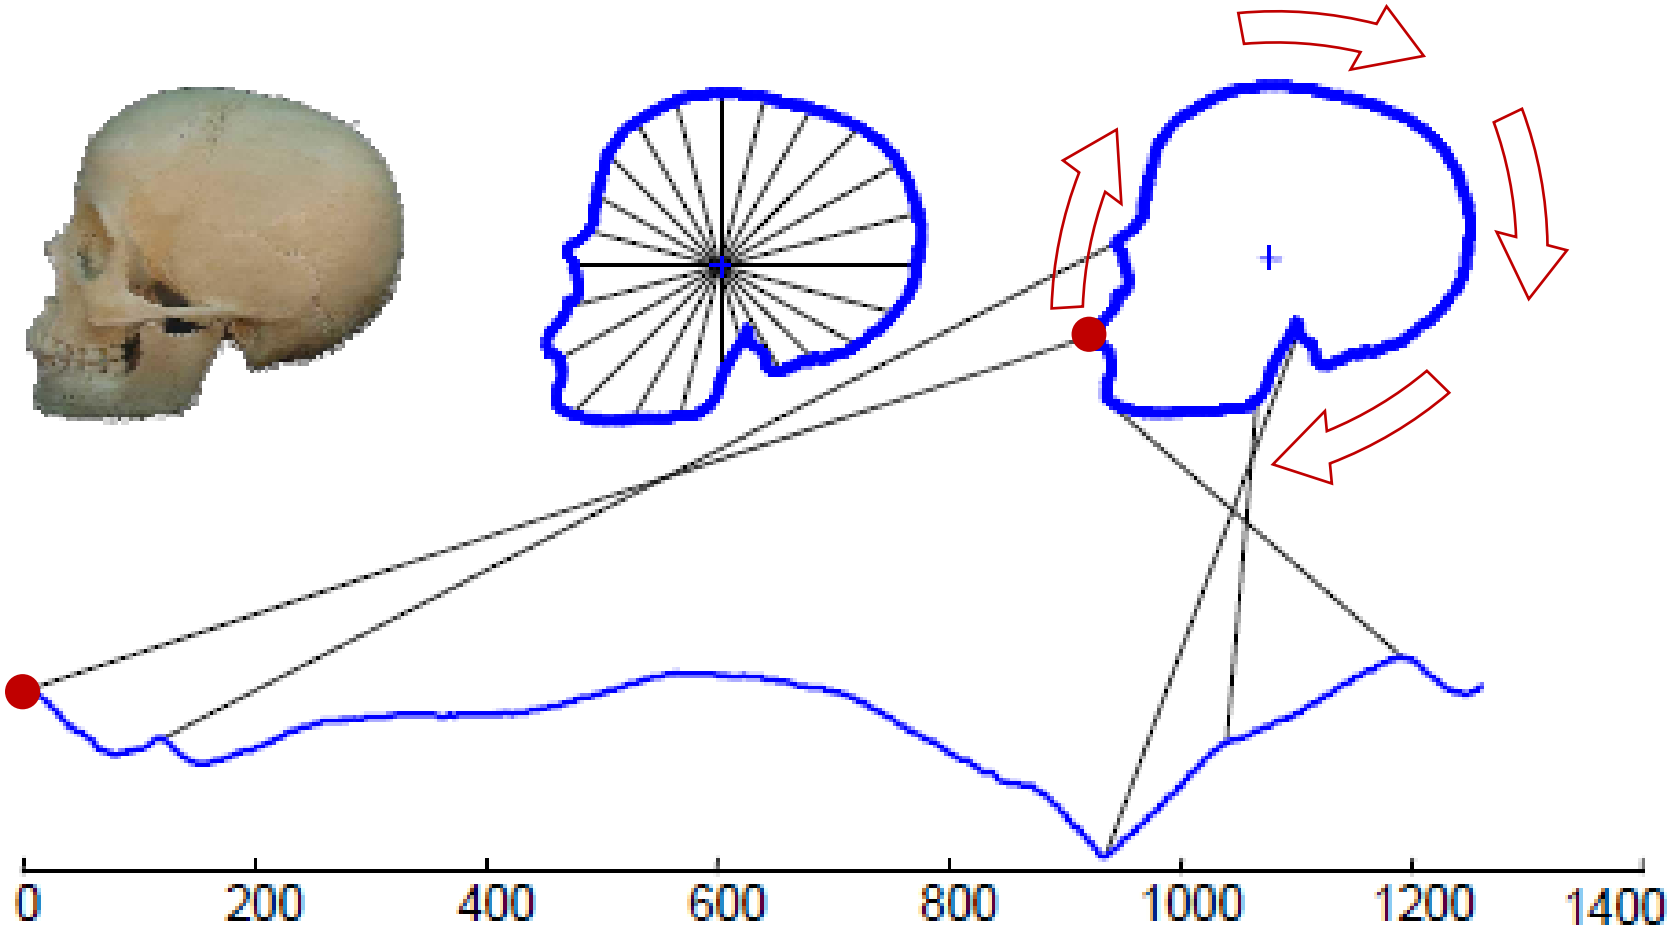


Текст как временной ряд



https://hedonometer.org – измерение и визуализация уровня счастья населения в на основе анализа публикаций в социальной сети Twitter (X)

Изображение (контур) как временной ряд



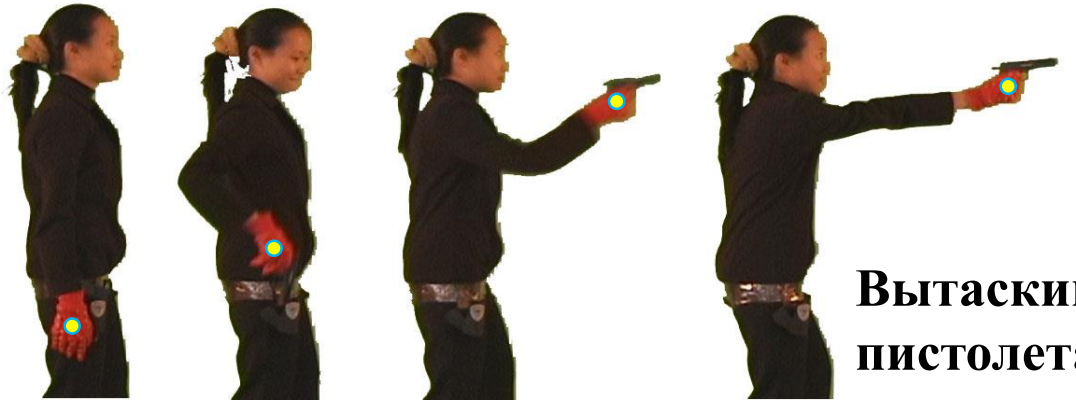
Keogh E. *et al.* LB_Keogh supports exact indexing of shapes under rotation invariance with arbitrary representations and distance measures. VLDB 2006. pp. 882-893. URL

Видео как временной ряд

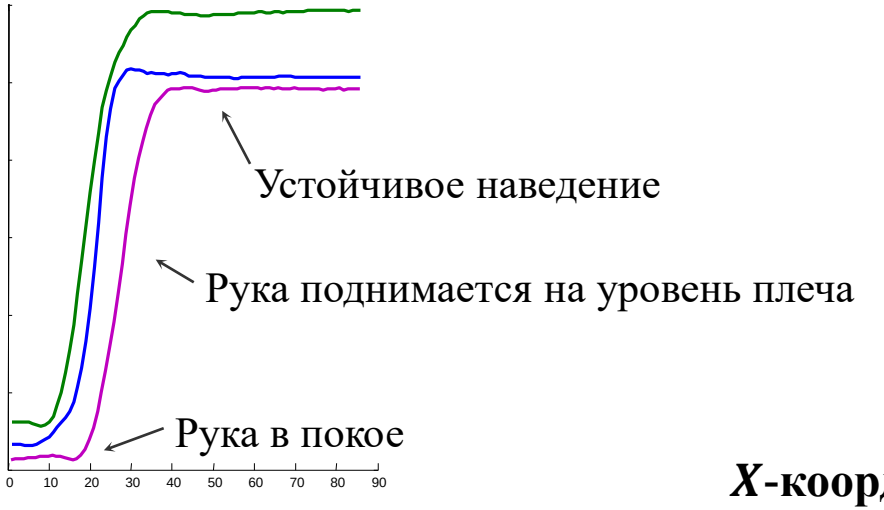
Классификация “Gun/No gun”



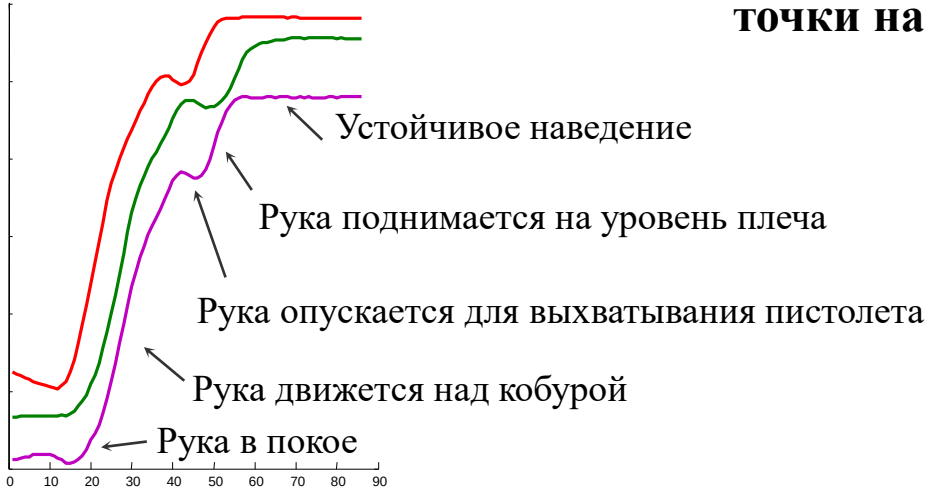
Указание рукой



Вытаскивание пистолета



***X*-координата точки на руке**

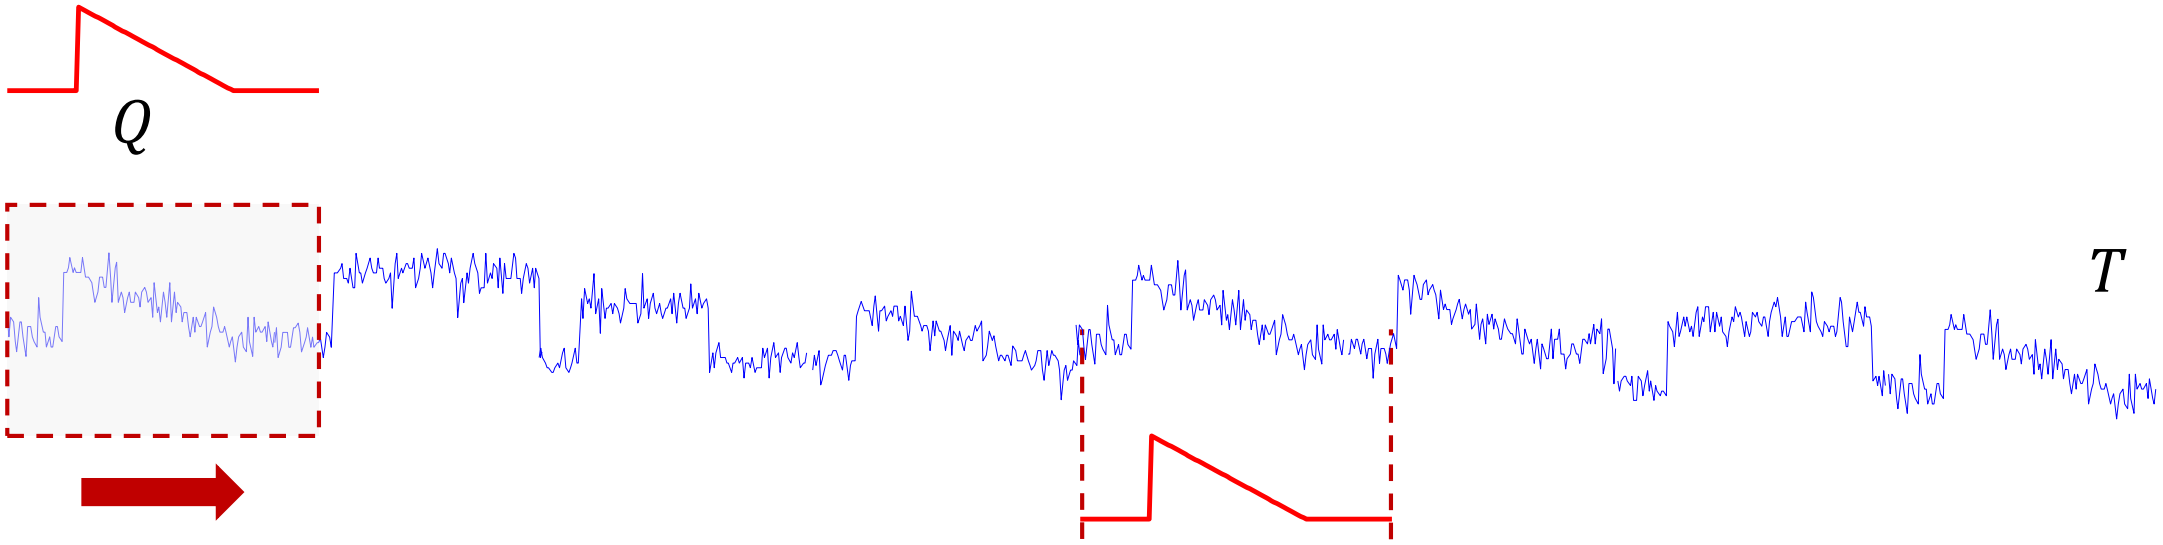


Keogh E. *et al.* A novel technique for indexing video surveillance data. First ACM SIGMM Int. workshop on Video surveillance. 2003. P. 98-106. https://doi.org/10.1145/982452.982465

Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- **Основные задачи интеллектуального анализа временных рядов**
  - Поиск по образцу
  - Поиск аномалий
  - Поиск паттернов
- Определения и нотация

Поиск по образцу (subsequence matching, similarity search)



В заданном ряде $T = \{C_1, \dots, C_n\}$ найти подпоследовательность $C_{\text{bestmatch}}$, наиболее похожую на заданный запрос Q:

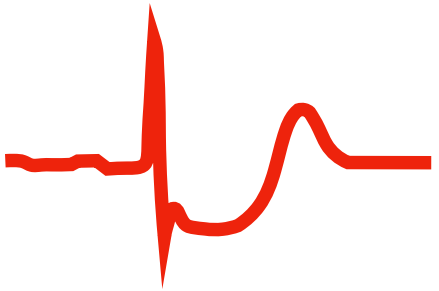
$$\forall T_{i,m} \in S_T^m \;\; \text{Dist}(C_{\text{bestmatch}}, Q) \leq \text{Dist}(C, Q)$$

Поиск по образцу: выявление заболеваний по ЭКГ

Преждевременное сокращение желудочков



Инфаркт



Гиперкалиемия



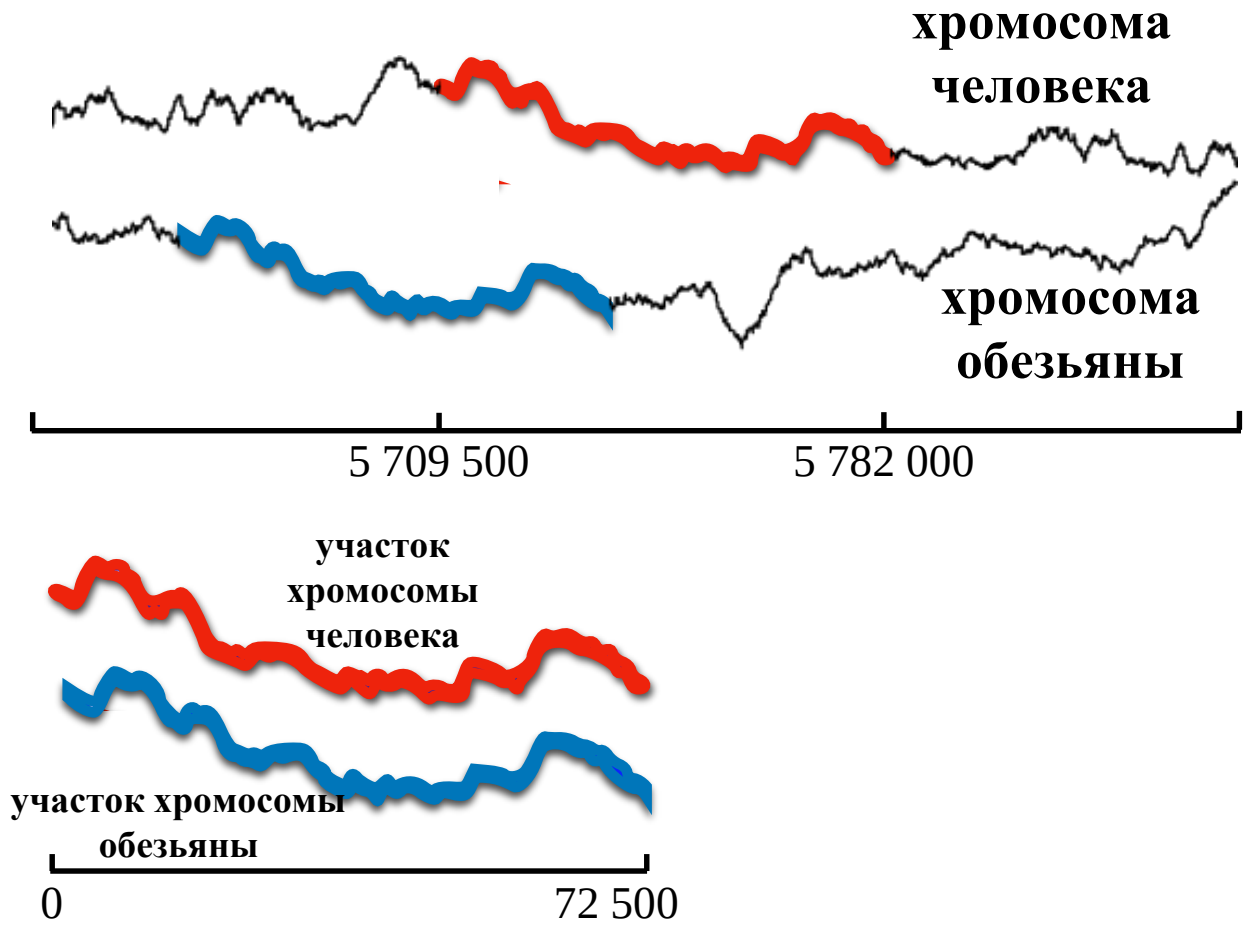


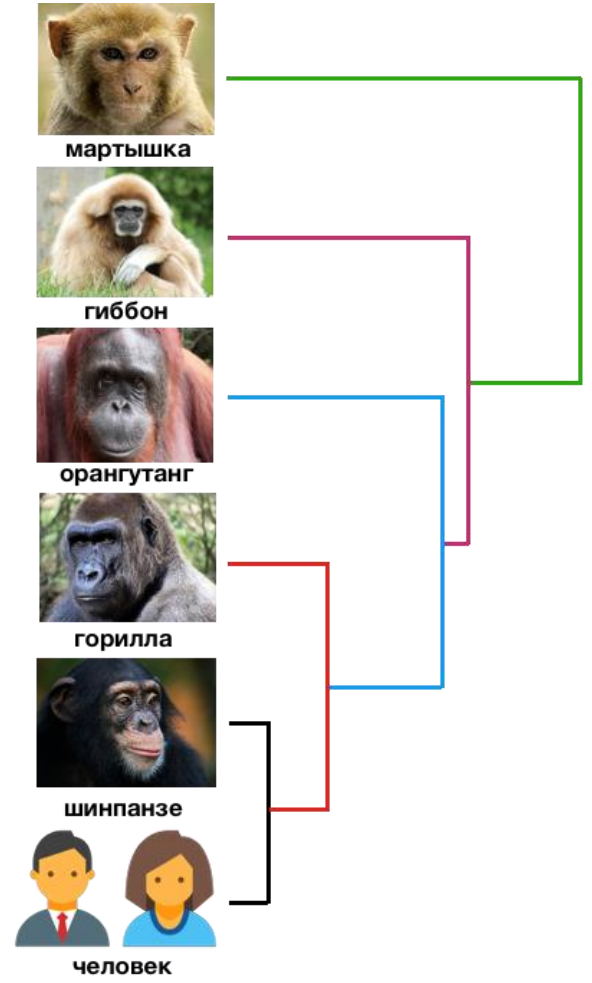
Поиск по образцу: генетика*

Хромосома человека:
GTCAAT…AAGAGATTTG
Хромосома обезьяны:
GGCAAT...ACAGATTTGA

Трансформация цепочки ДНК во временной ряд

$t_1 := 0$
for $i \in 1..|DNAstr|$ **do**
  case $DNAstr$ **of**
  A : $t_{i+1} := t_{i+2}$
  G : $t_{i+1} := t_{i+1}$
  C : $t_{i+1} := t_{i-1}$
  T : $t_{i+1} := t_{i-2}$
  end



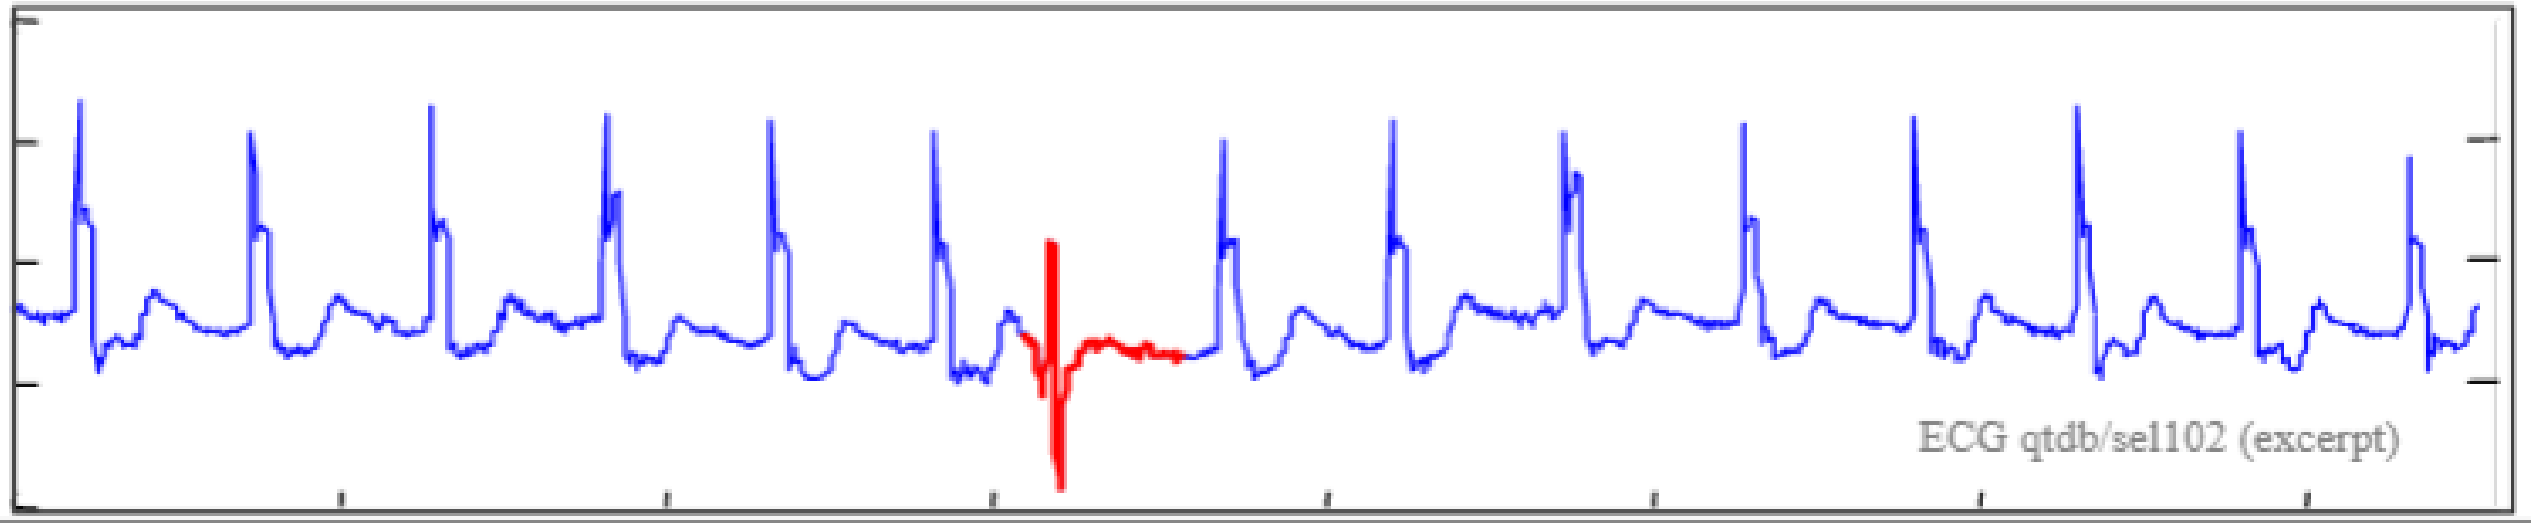


* Rakthanmanon T. *et al.* Addressing big data time series: Mining trillions of time series subsequences under Dynamic Time Warping. ACM TKDD. 2013. 7(3). 10. https://doi.org/10.1145/2500489

Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- **Основные задачи интеллектуального анализа временных рядов**
  - Поиск по образцу
  - Поиск аномалий
  - Поиск паттернов
- Определения и нотация

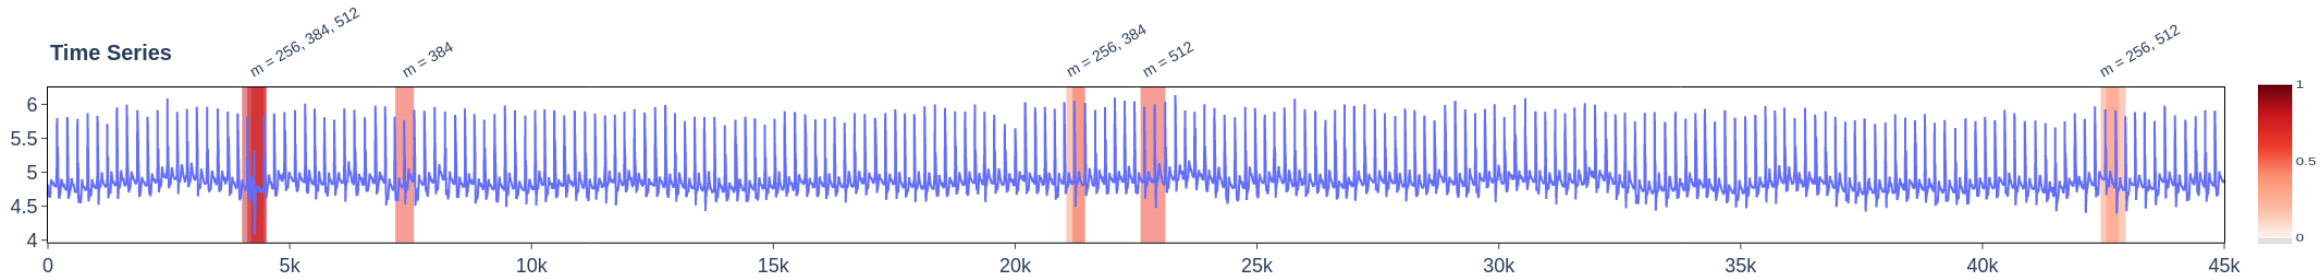
Поиск аномалий временного ряда



В заданном временном ряде найти подпоследовательность, наиболее непохожую на все остальные подпоследовательности ряда

Поиск аномалий

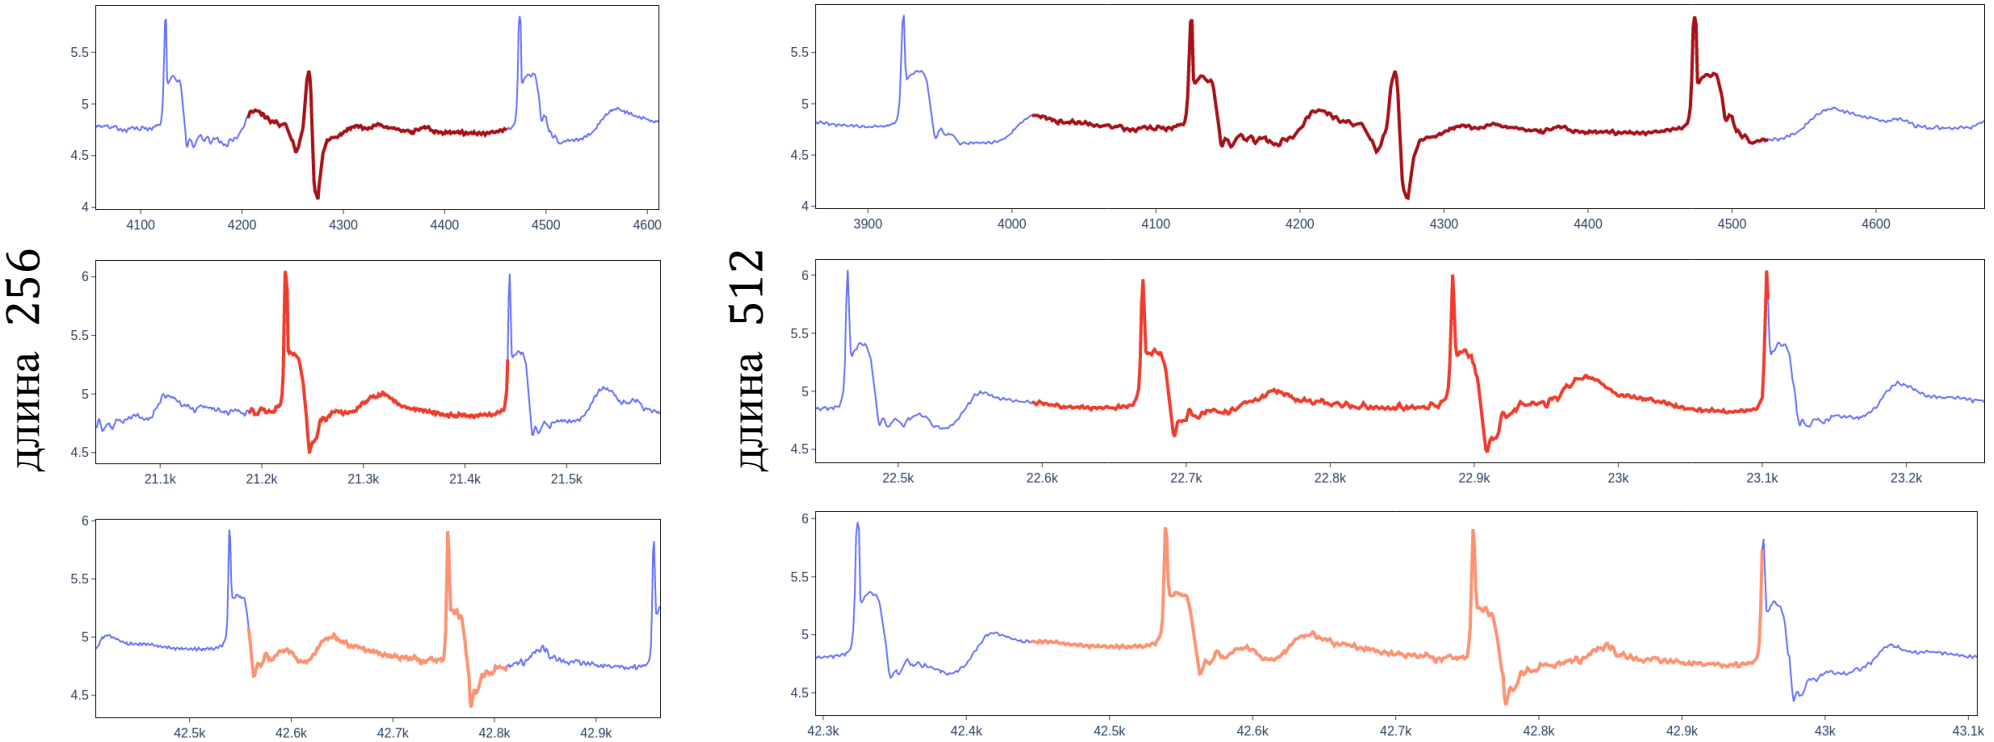
ЭКГ взрослого пациента



Прежде-временное сокращение желудочков

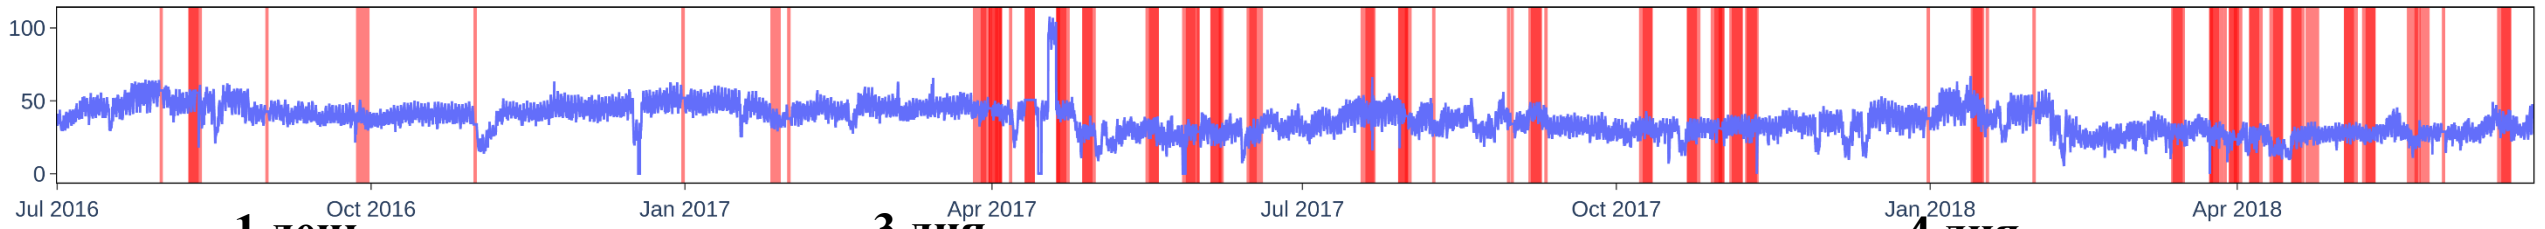
Эктопическое сердцебиение

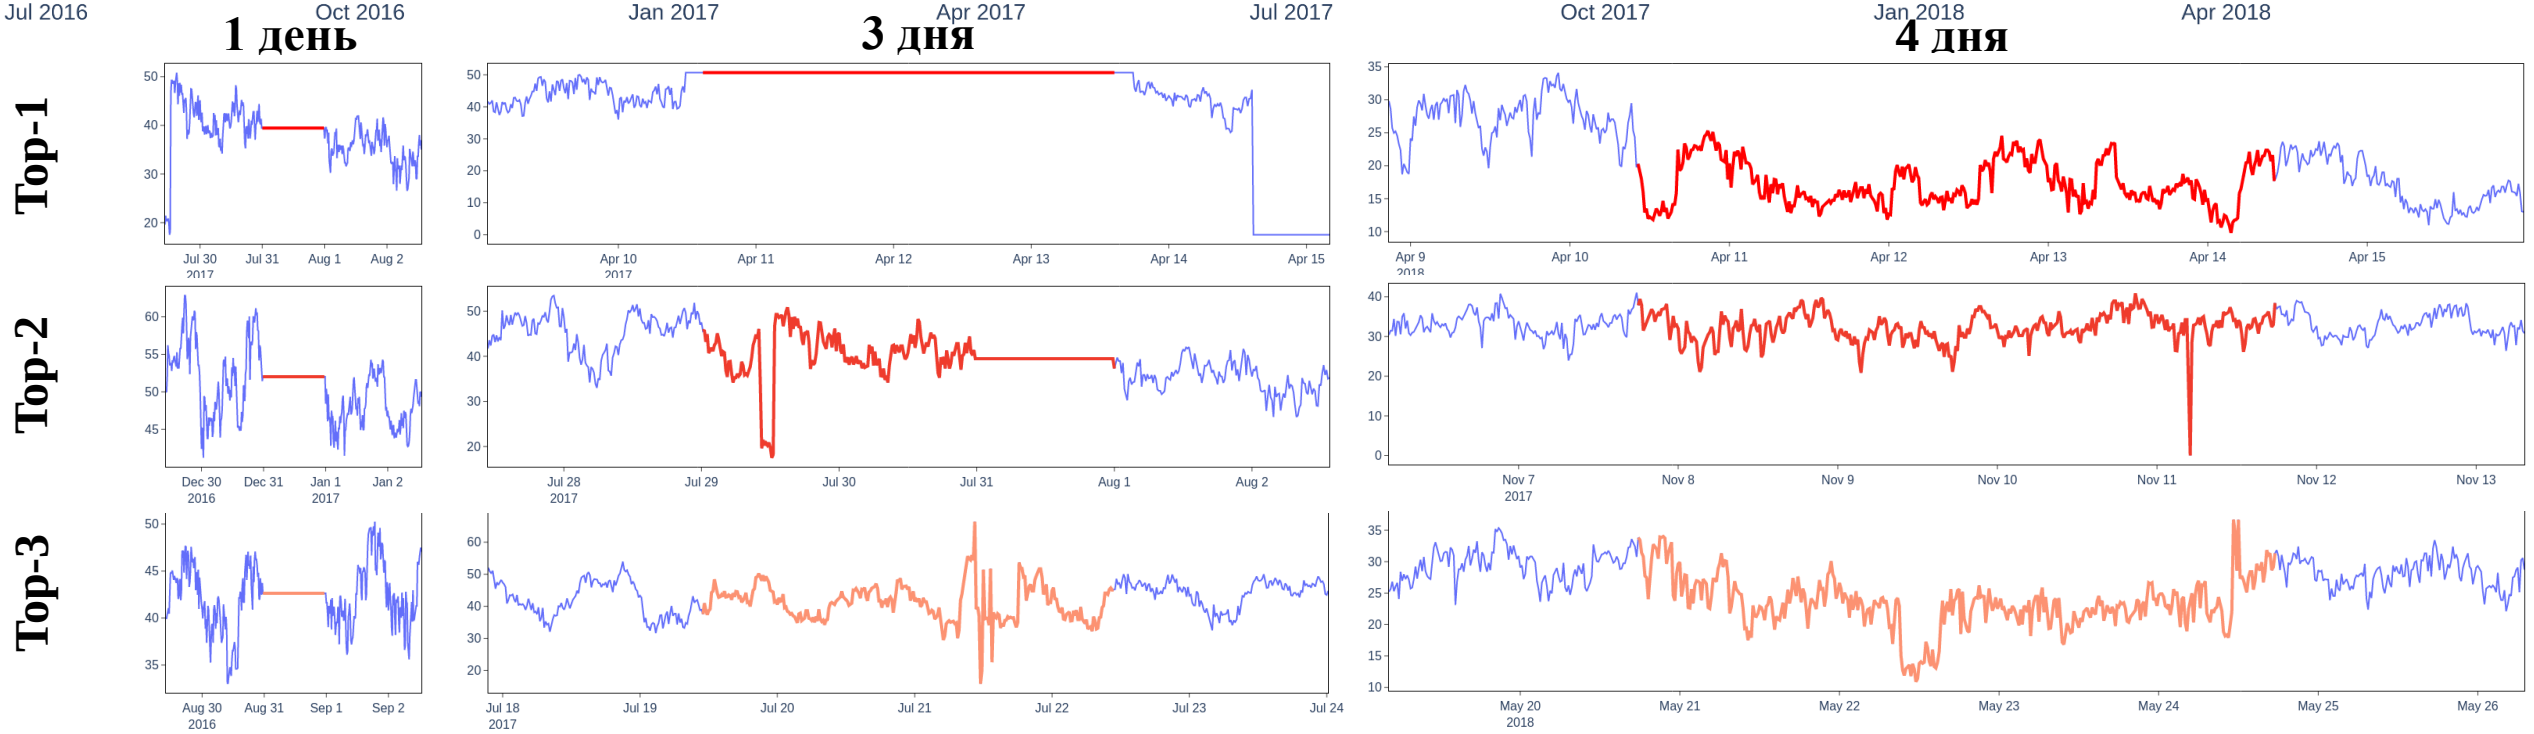
Эктопическое сердцебиение



Поиск аномалий

Двухгодичное энергопотребление в Китае*



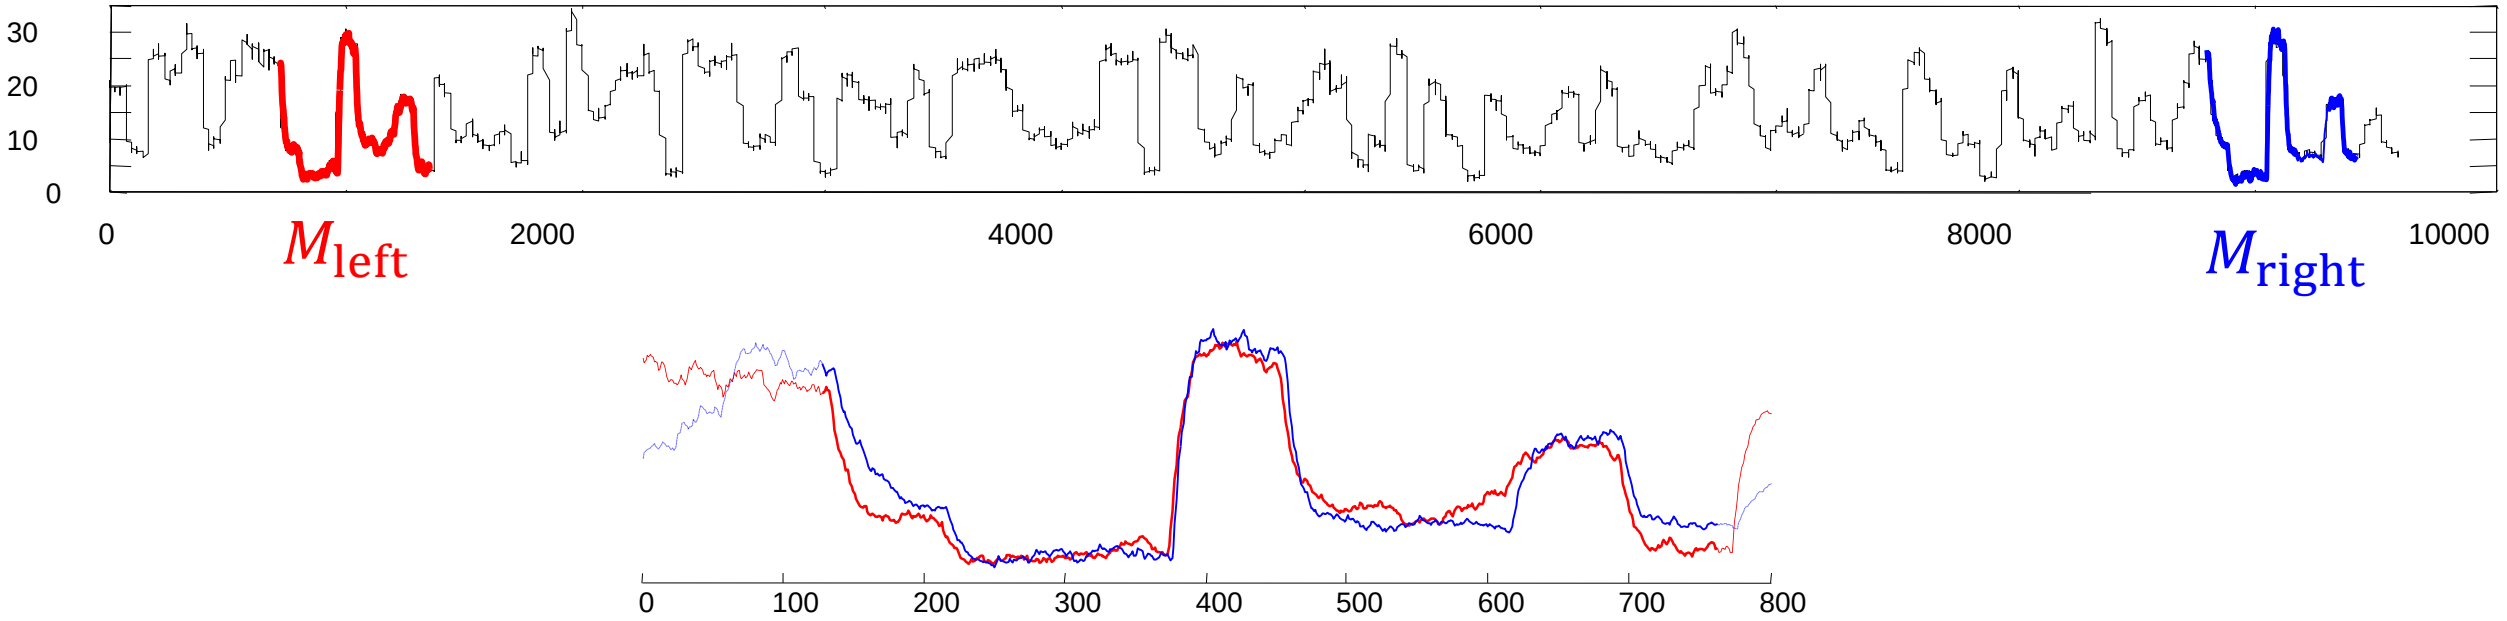


* Zhou H. *et al.* Informer: beyond efficient transformer for long sequence time-series forecasting. AAAI 2021: 11106-11115. DOI: 10.1609/aaai.v35i12.17325.

Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- **Основные задачи интеллектуального анализа временных рядов**
  - Поиск по образцу
  - Поиск аномалий
  - Поиск паттернов
    - Мотивы
    - Поведенческие паттерны
    - Эволюционирующие паттерны
- Определения и нотация

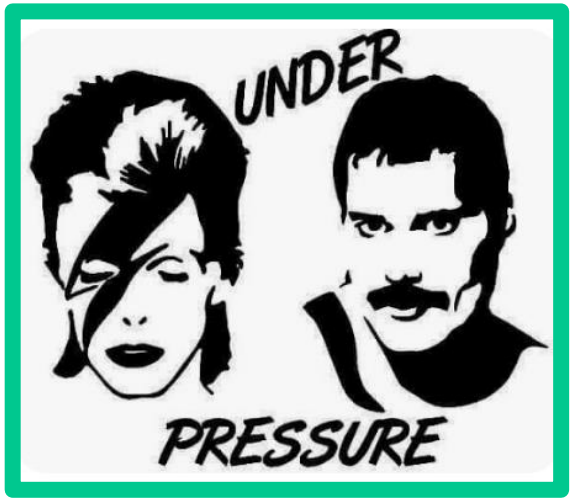
Поиск паттернов: мотивы (motifs)

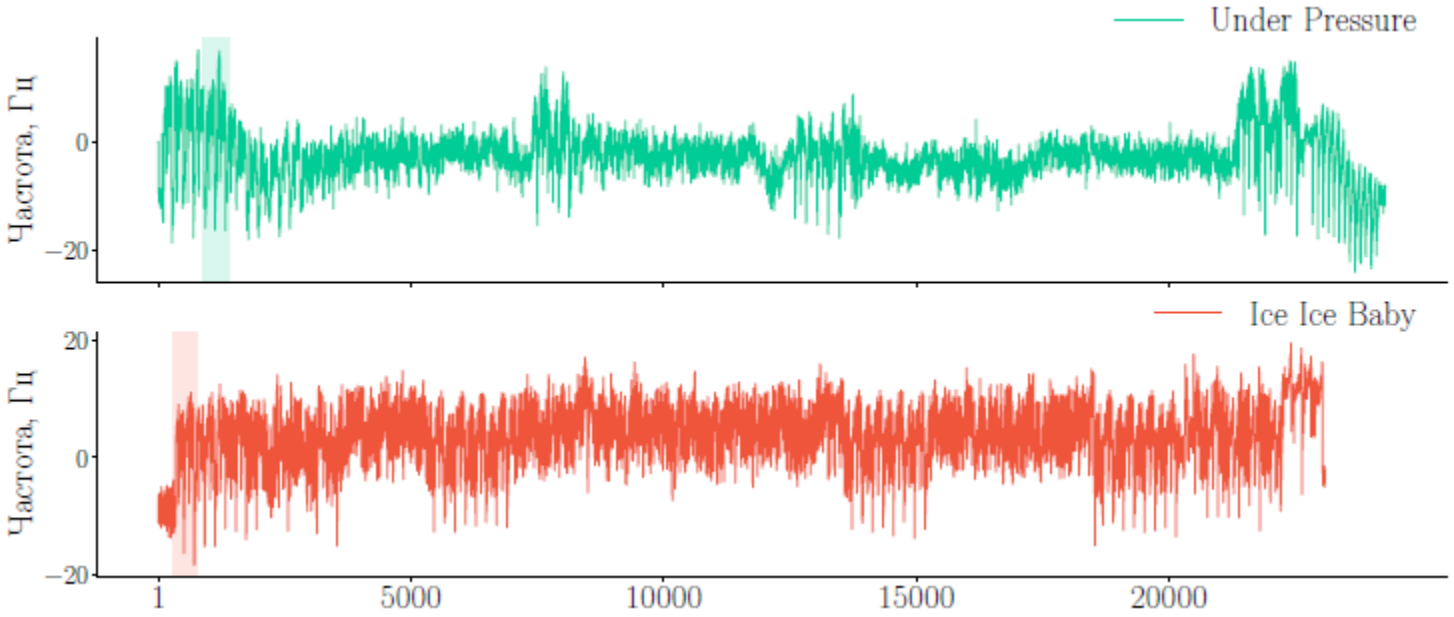


Пара непересекающихся подпоследовательностей ряда равной длины, наиболее похожих друг на друга:

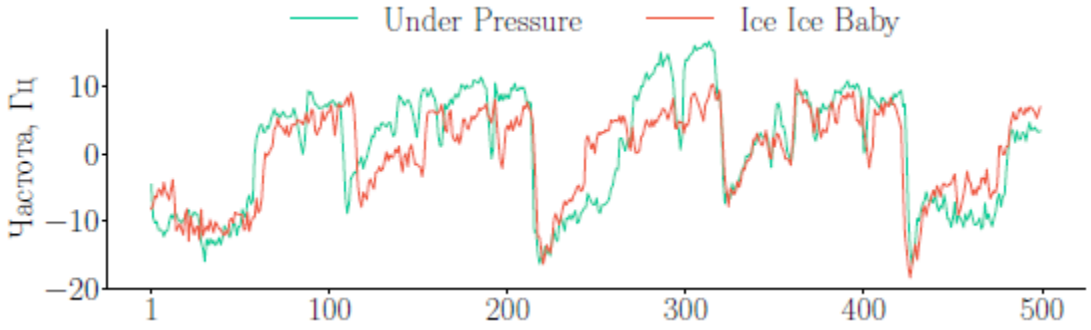
$$\forall C_i, C_j \;\; \text{Dist}\left(M_{\text{left}}, M_{\text{right}}\right) \leq \text{Dist}(C_i, C_j)$$
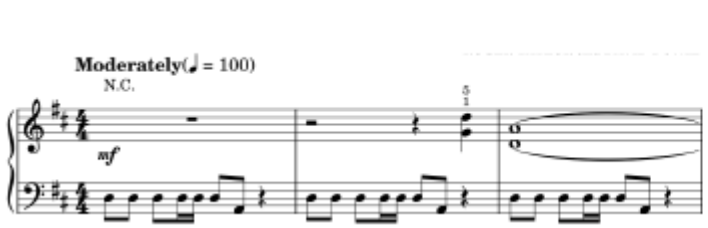
Поиск паттернов: мотивы (motifs)
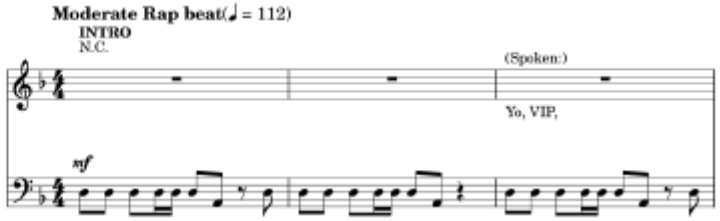




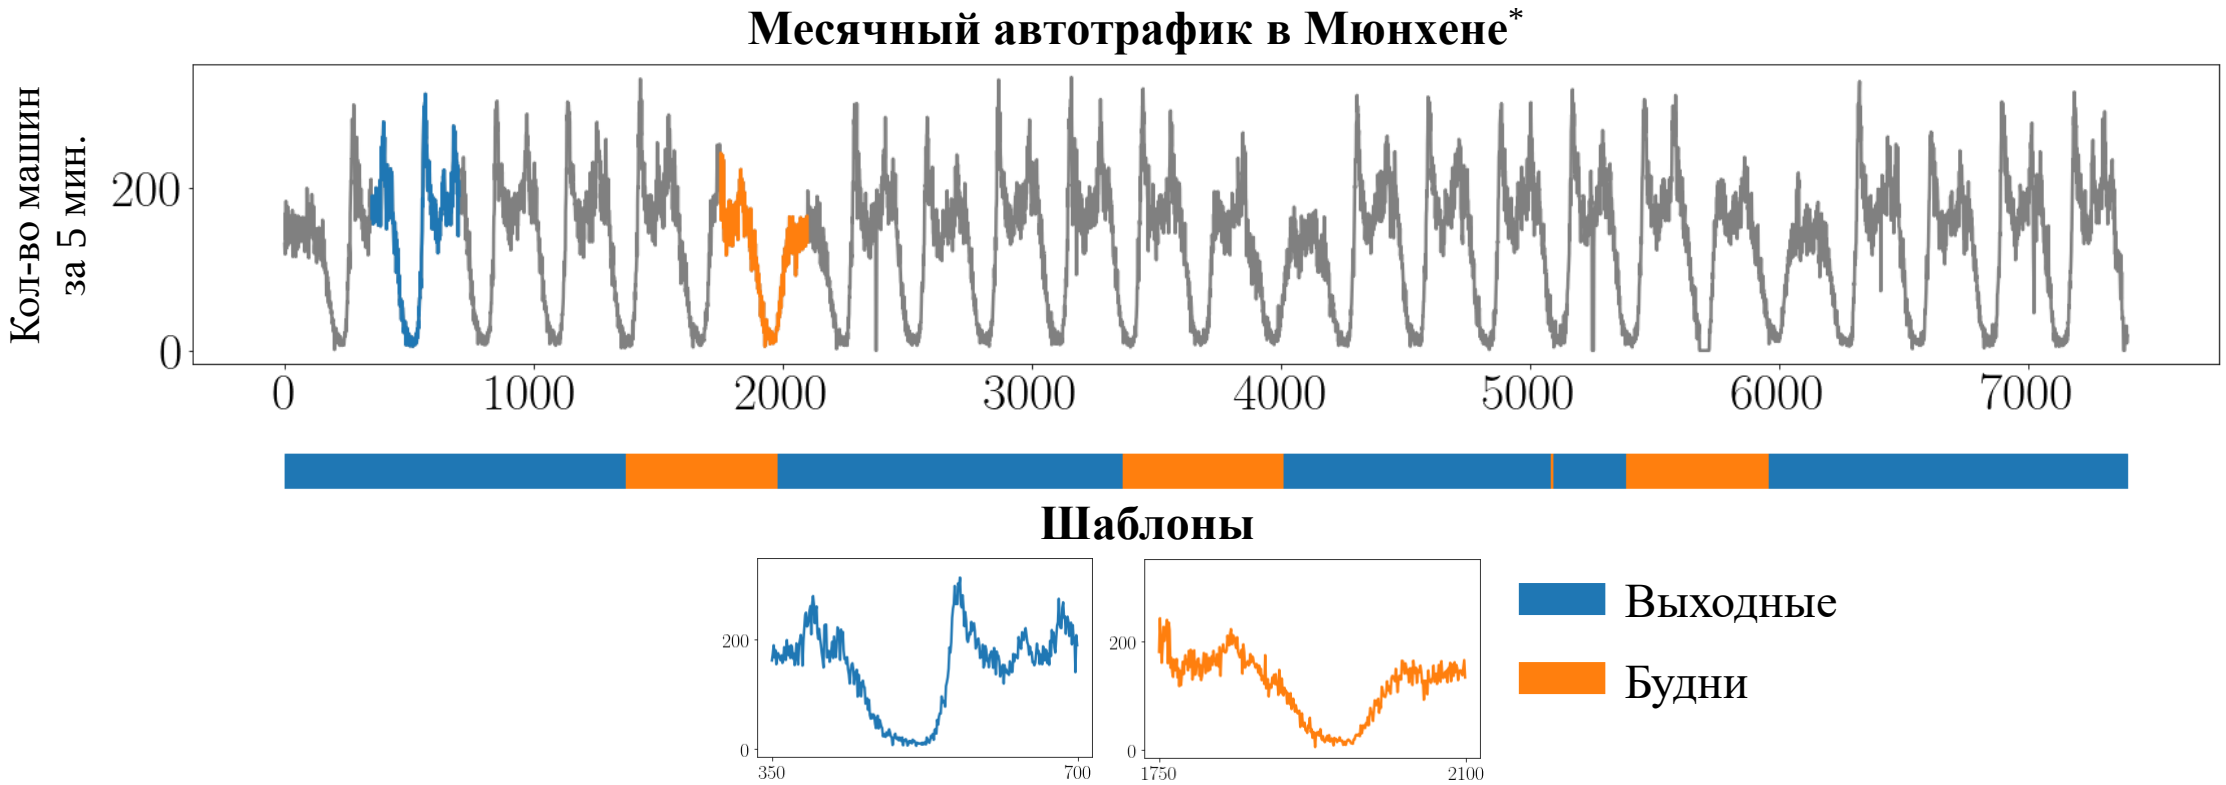








Поиск паттернов: поведенческие шаблоны

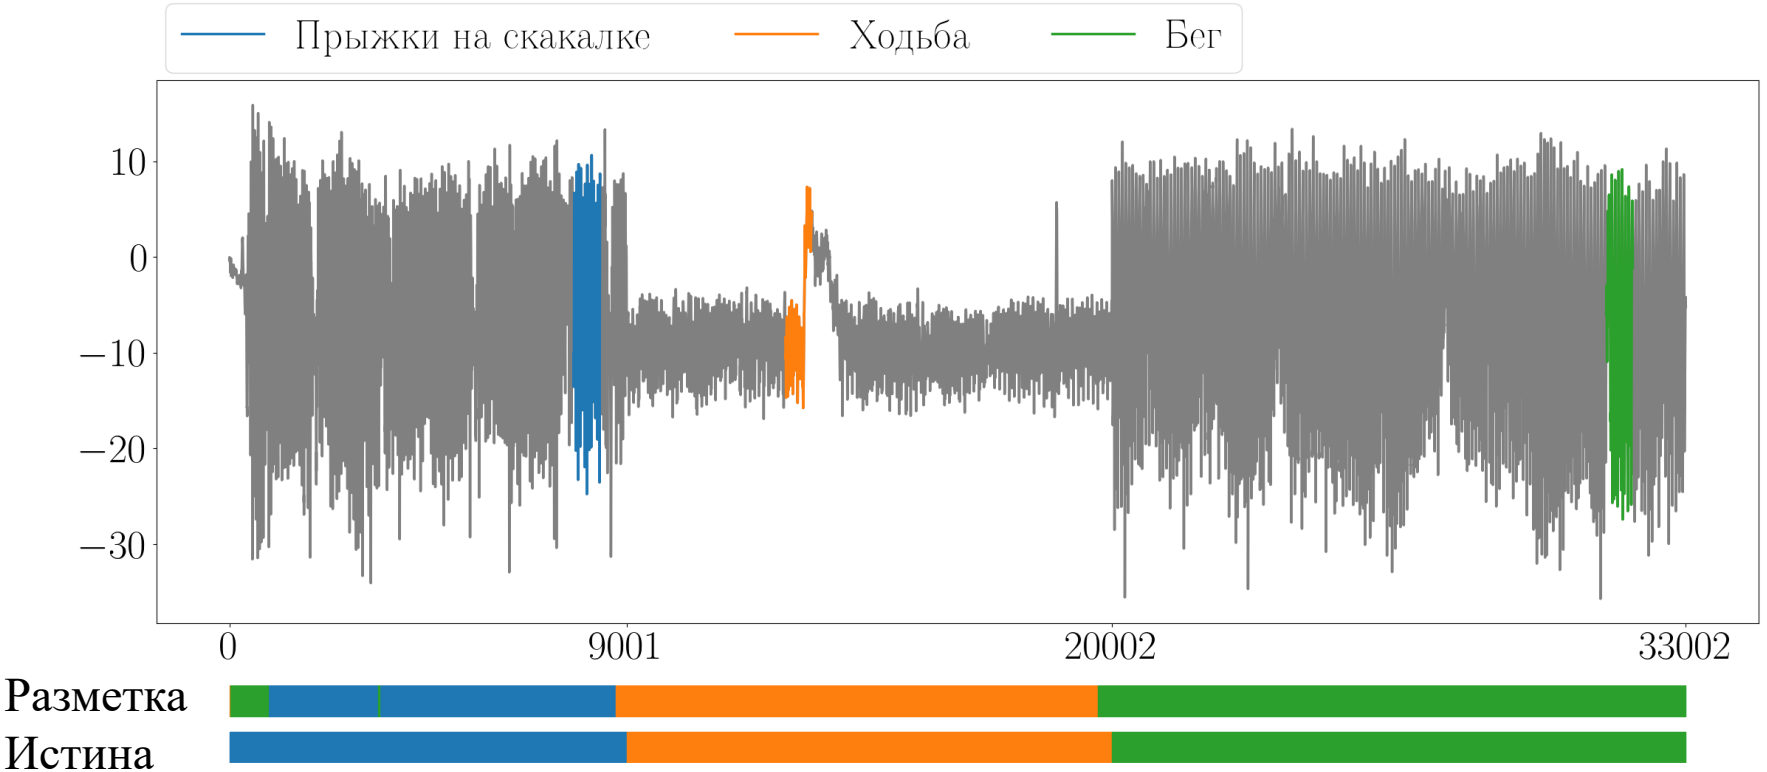


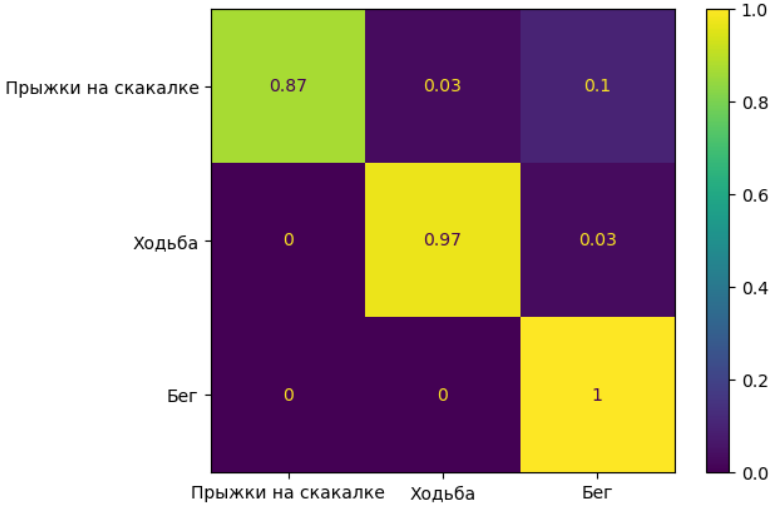
Множество подпоследовательностей ряда, выражающих типичные активности объекта

* Public (anonymized) road traffic prediction datasets from Huawei Munich Research Center. URL: https://zenodo.org/record/3653880#.Y0zZi3ZBxPa

Поиск паттернов: поведенческие шаблоны

Показания носимого акселерометра



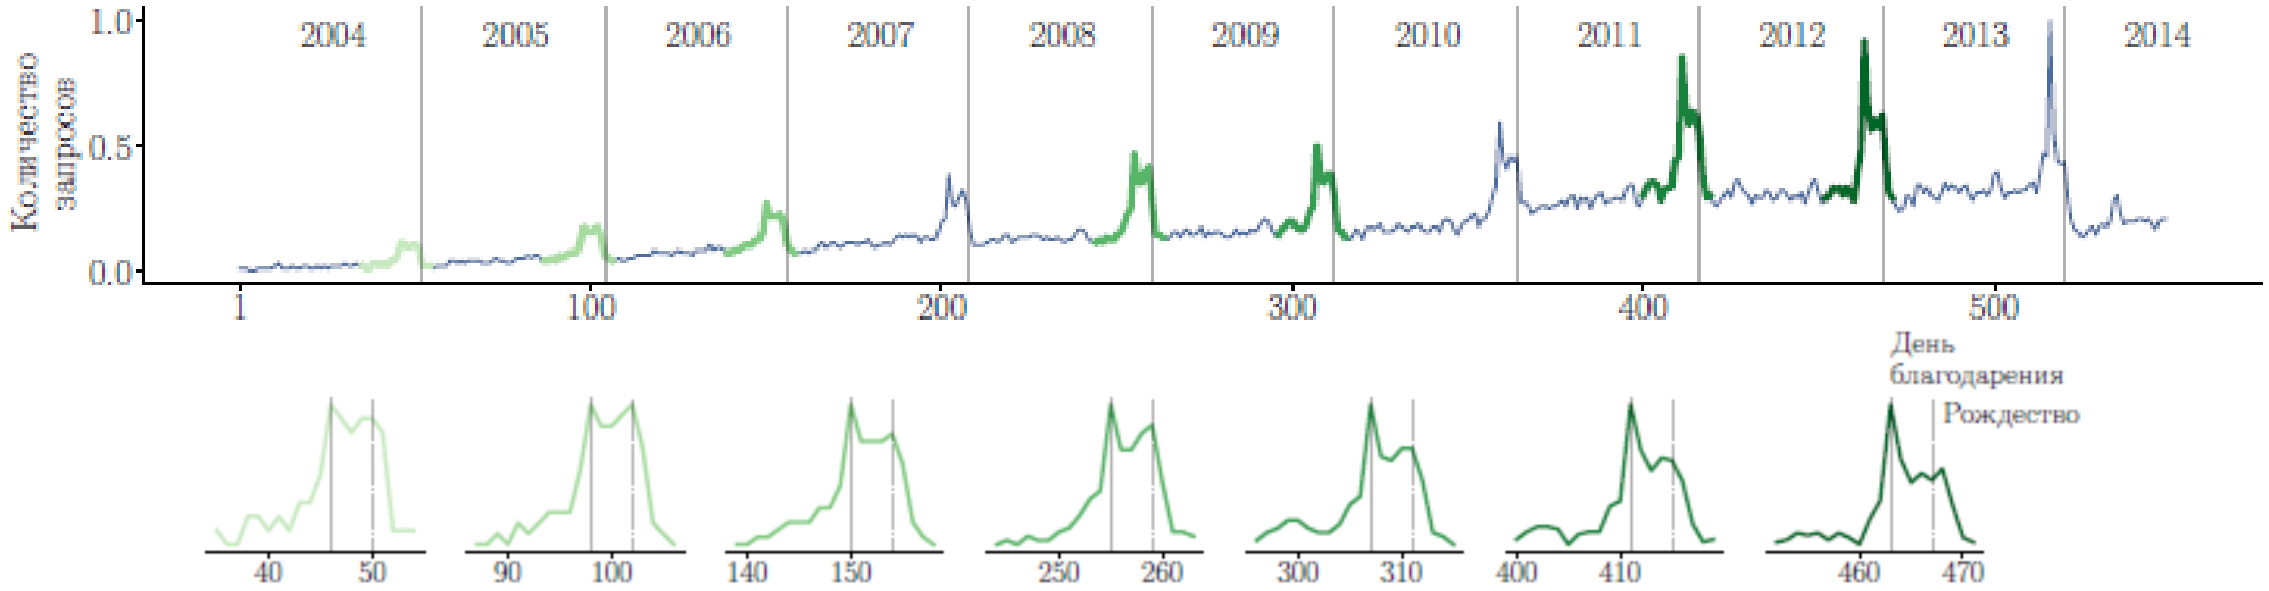


Активность	Precision	Recall	F1
Прыжки	1	0.87	0.93
Ходьба	0.98	0.97	0.97
Бег	0.77	1	0.87

* Reiss A., Stricker D. Introducing a new benchmarked dataset for activity monitoring. ISWC 2012, Newcastle, UK, June 18-22, 2012. 108–109. IEEE (2012). doi: 10.1109/ISWC.2012.13

Поиск паттернов: эволюционирующие шаблоны

Число запросов Google, содержащих KOHL'S (розничная сеть в США)

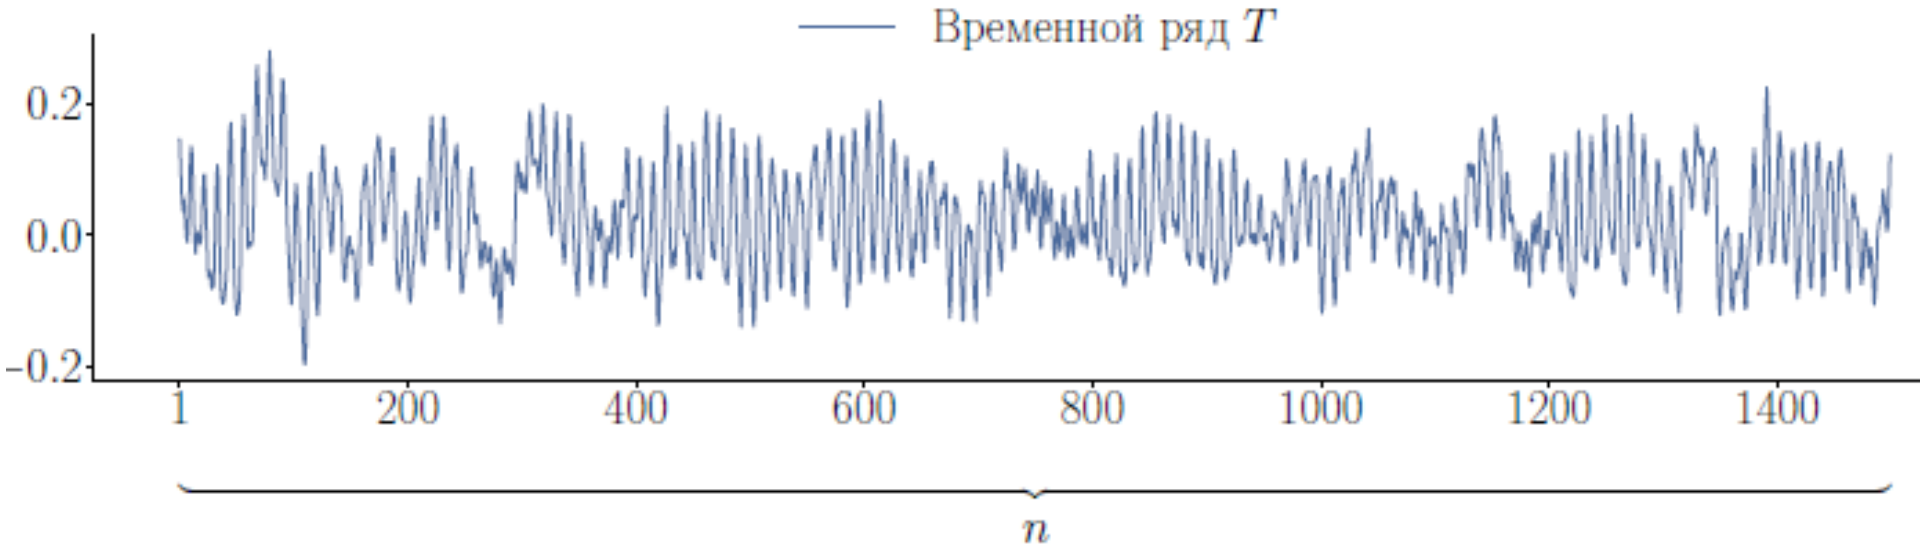


- **Рост важности Киберпонедельника** (понедельник после Дня благодарения):
  за 10 лет выпуклость меняется от плавной и занимающей больший период
  между Днем благодарения и Рождеством к резкой и сосредоточенной на Дне благодарения
- Термин введен в пресс-релизе “Киберпонедельник становится одним из крупнейших дней онлайн-покупок в году” 28 ноября 2005 г., дата которого совпадает с первым проблеском острого пика в цепочке

Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- Основные задачи интеллектуального анализа временных рядов
- **Определения и нотация**
  - Временной ряд и подпоследовательность
  - Функции расстояния
  - Тривиальные совпадения
  - Ближайший сосед

(Одномерный) временной ряд (univariate time series)



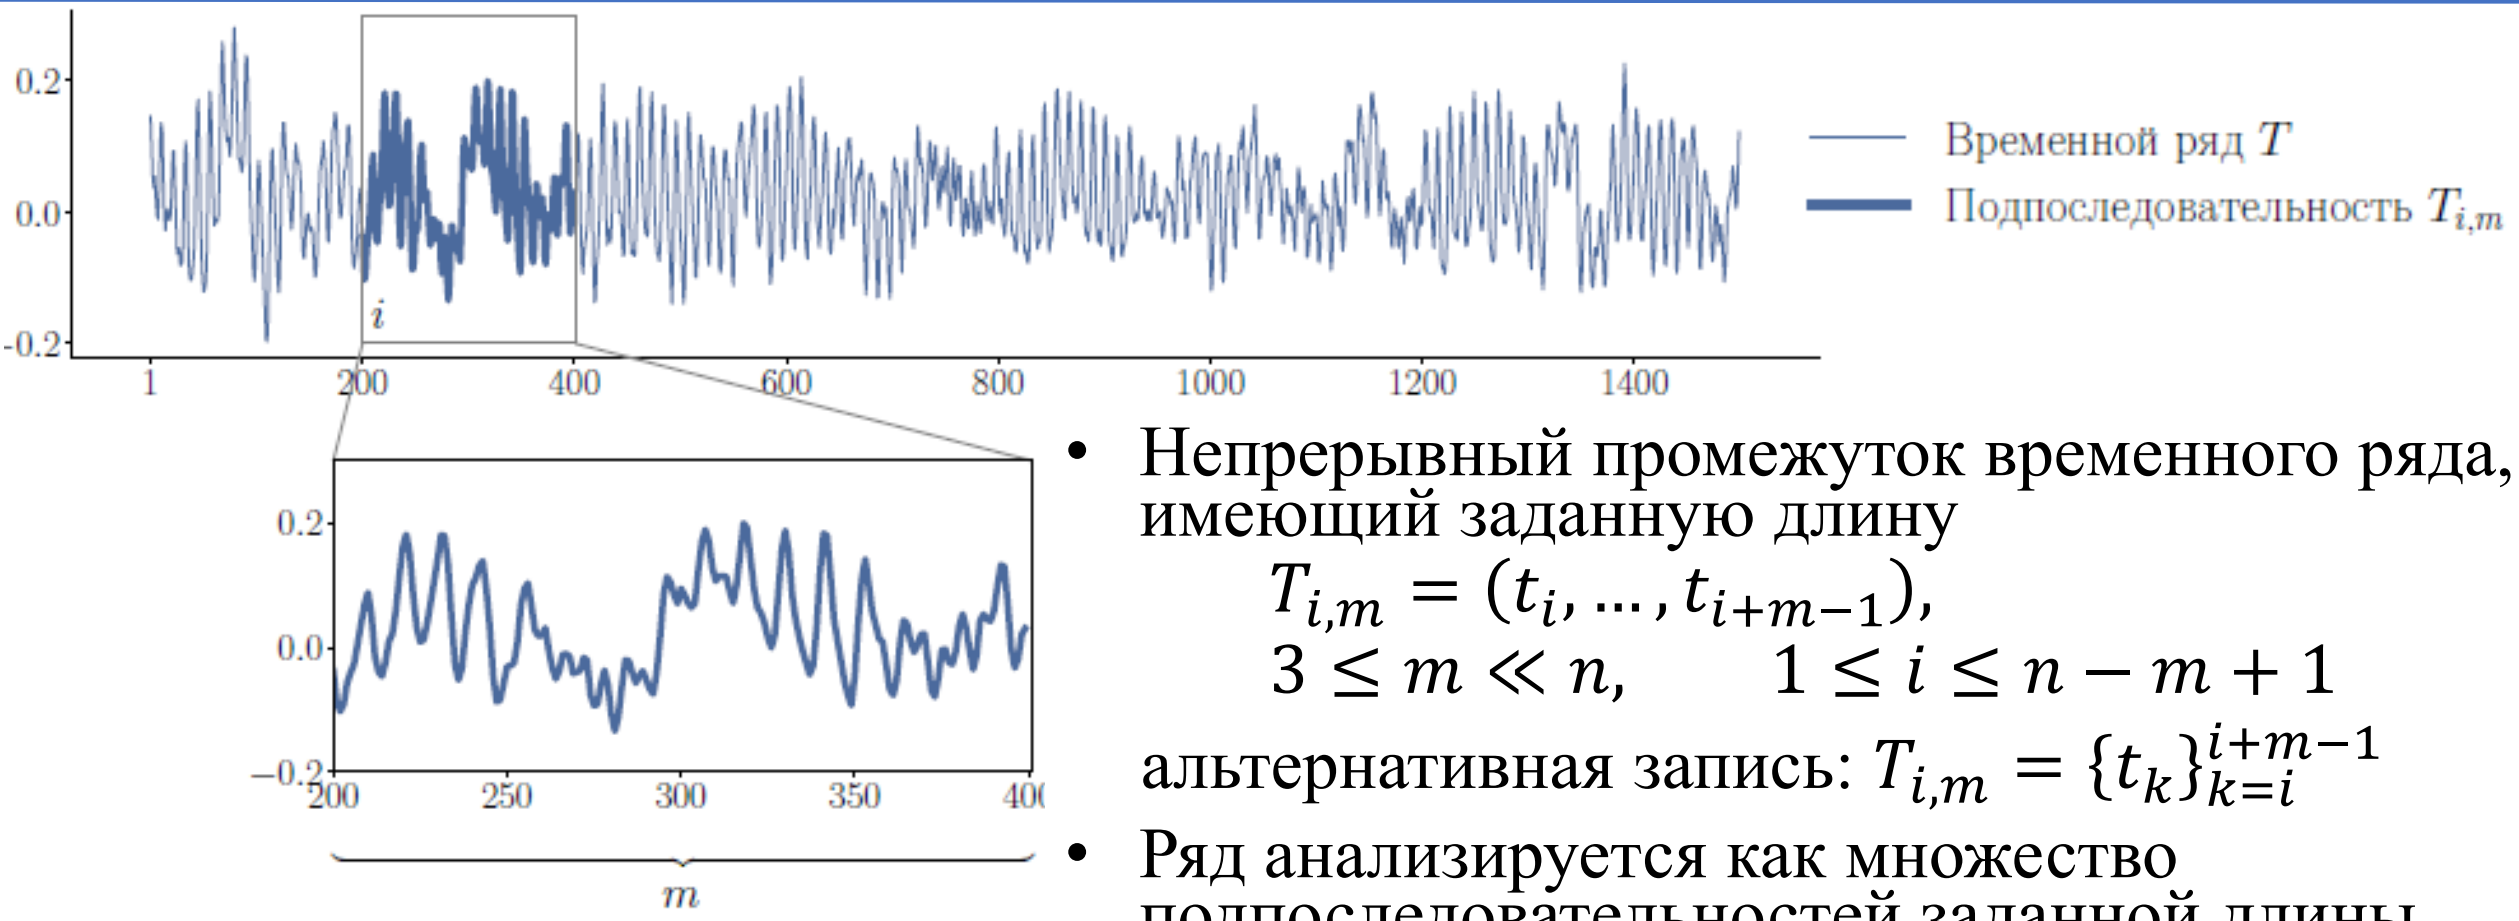
- Конечная последовательность хронологически упорядоченных вещественных значений

$$T = (t_1, \dots, t_n), \qquad t_i \in \mathbb{R}$$

альтернативная запись: $T = \{t_i\}_{i=1}^{n}$

n – длина ряда, $|T| = n$

Подпоследовательность (subsequence)



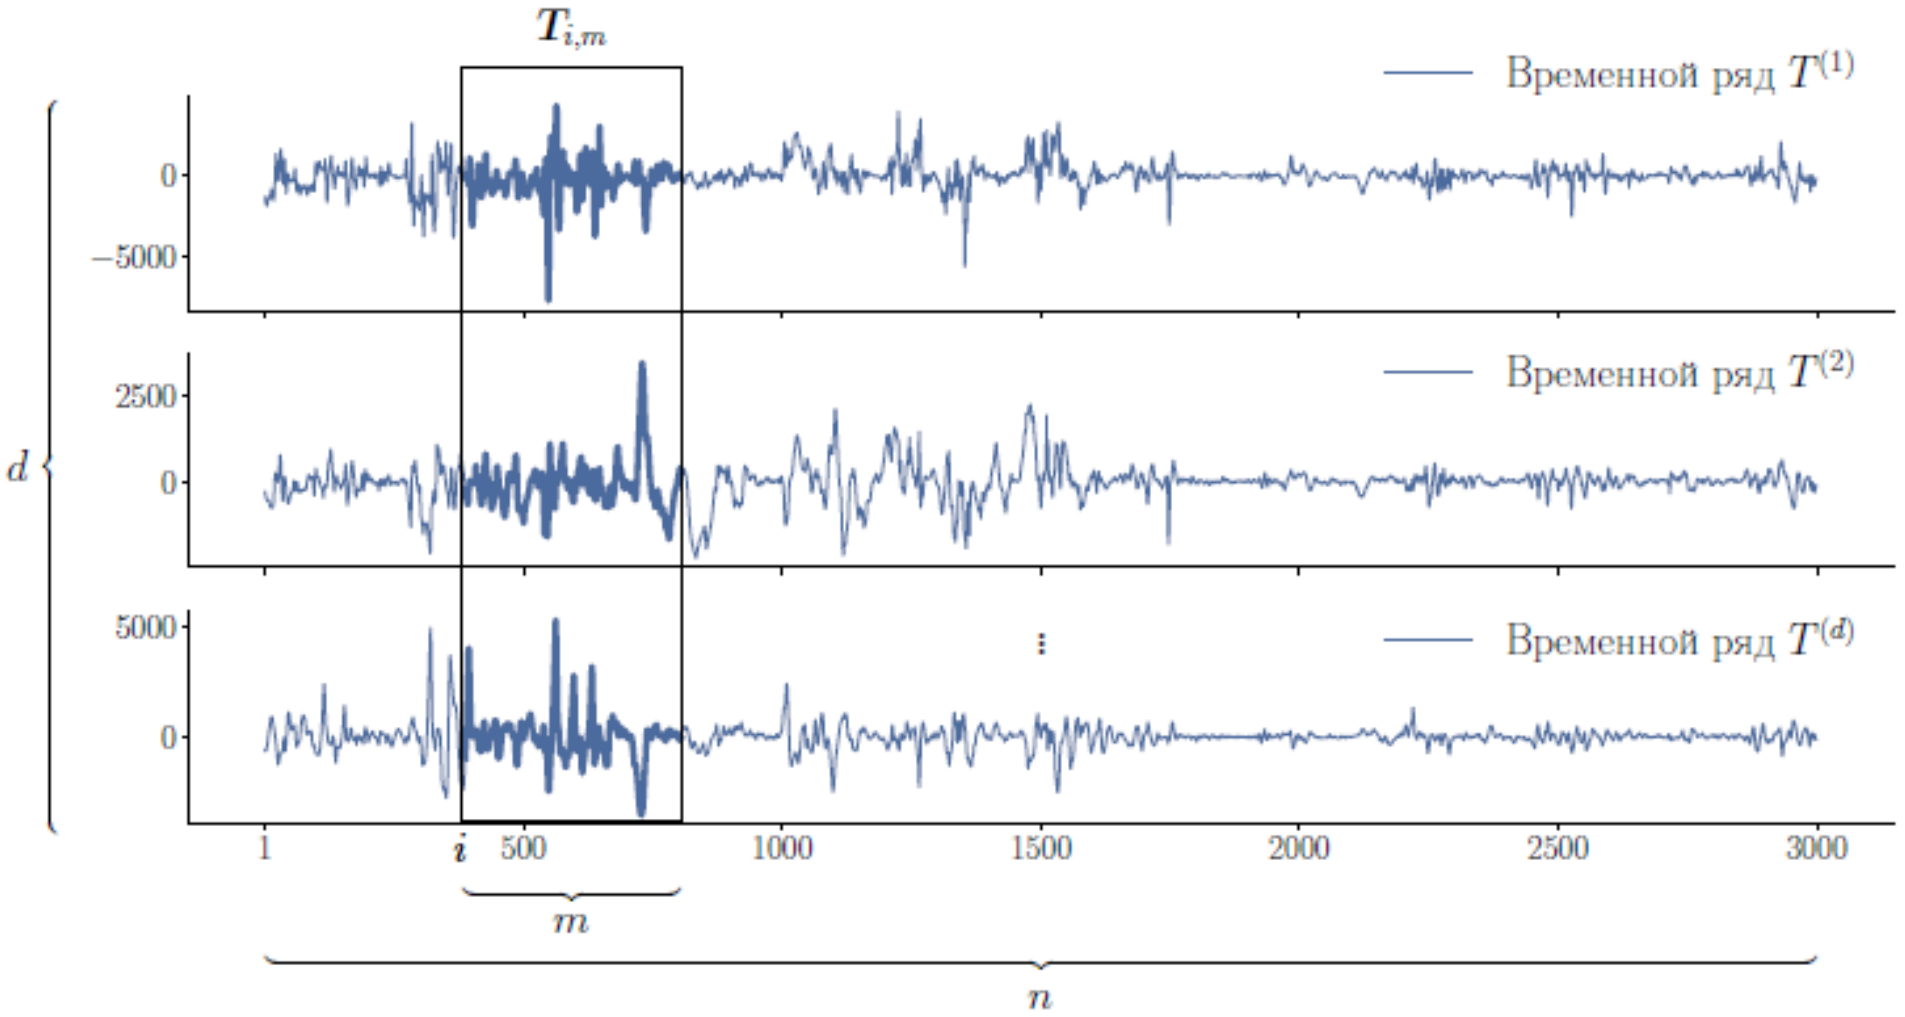
- Непрерывный промежуток временного ряда, имеющий заданную длину

$$T_{i,m} = (t_i, \dots, t_{i+m-1}),$$
$$3 \le m \ll n, \qquad 1 \le i \le n - m + 1$$

альтернативная запись: $T_{i,m} = \{t_k\}_{k=i}^{i+m-1}$

- Ряд анализируется как множество подпоследовательностей заданной длины
- Обычно $0.01n \le m \le 0.1n$

Многомерный временной ряд (multivariate time series)



Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- Основные задачи интеллектуального анализа временных рядов
- **Определения и нотация**
  - Временной ряд и подпоследовательность
  - Функции расстояния
  - Тривиальные совпадения
  - Ближайший сосед

Аксиомы метрики: Dist: $M \times M \to \mathbb{R}$: $\forall x, y, z \in M$

- Аксиома тождества:
$$\mathrm{Dist}(x, x) = 0$$
- Аксиома положительности:
$$\mathrm{Dist}(x, y) \geq 0$$
- Аксиома симметричности:
$$\mathrm{Dist}(x, y) = \mathrm{Dist}(y, x)$$
- Аксиома (неравенство) треугольника:
$$\mathrm{Dist}(x, z) \leq \mathrm{Dist}(x, y) + \mathrm{Dist}(y, z)$$

Метрика

Функция расстояния

Ослабленная функция расстояния

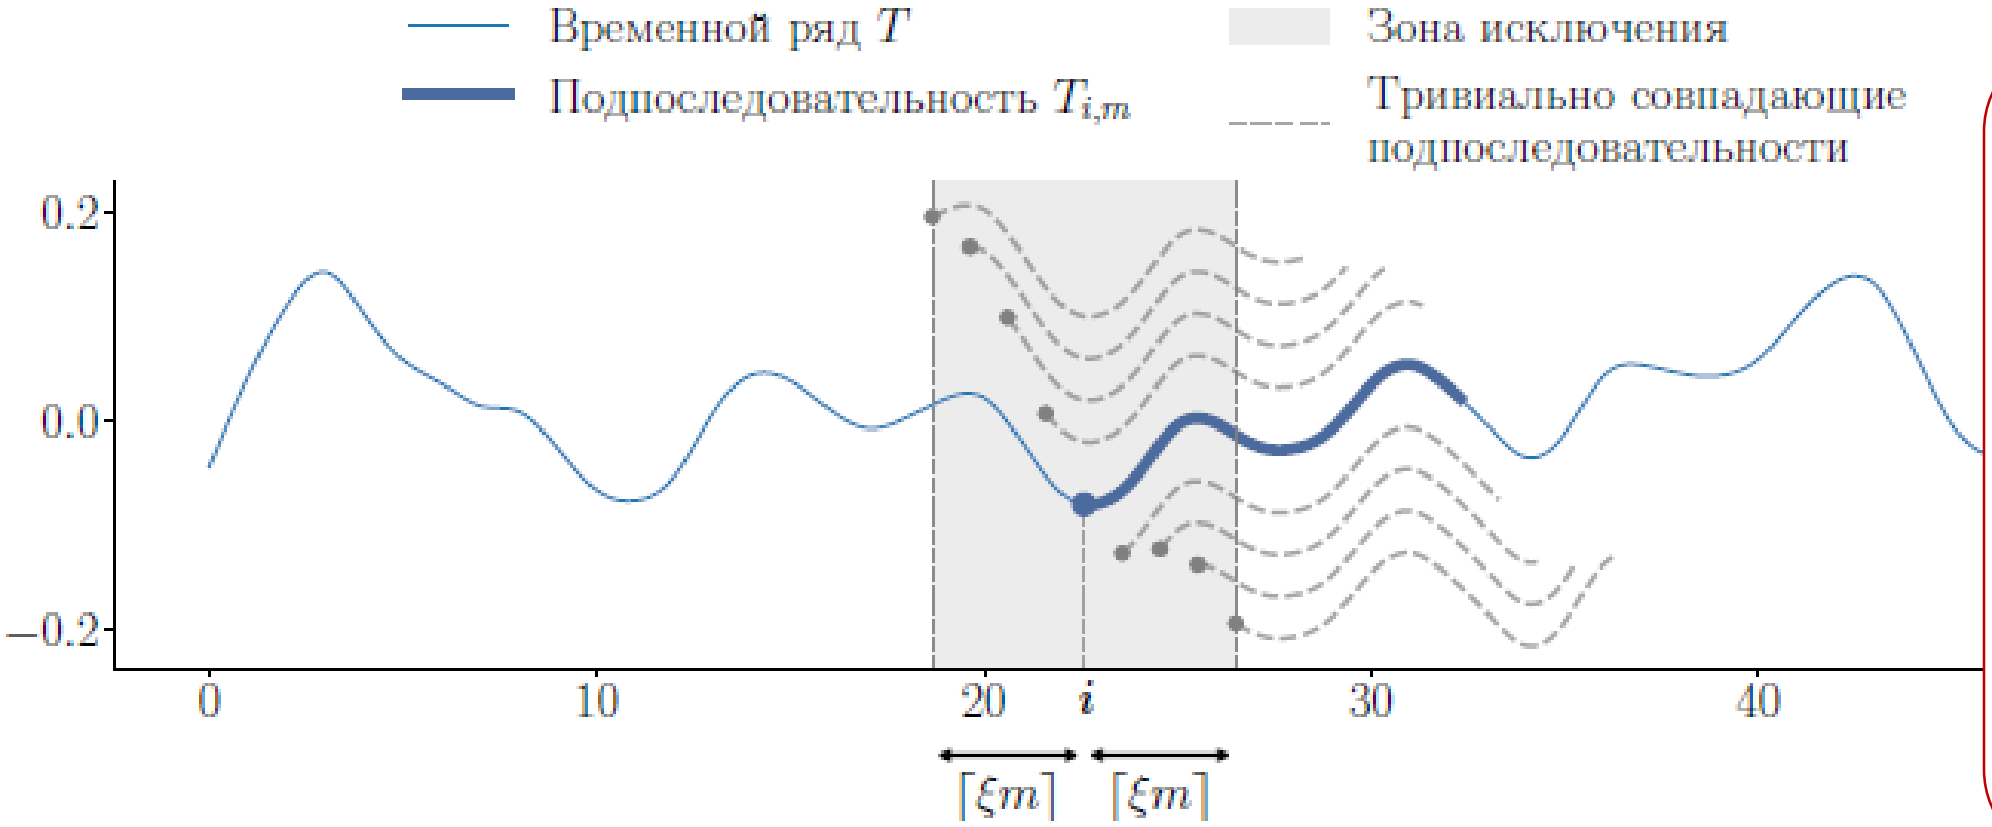
Иерархия функций расстояния



Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- Основные задачи интеллектуального анализа временных рядов
- **Определения и нотация**
  - Временной ряд и подпоследовательность
  - Функции расстояния
  - Тривиальные совпадения
  - Ближайший сосед

Тривиальные совпадения (trivial matches)



Тривиальные совпадения не представляют ценности независимо от функции расстояния

(они неотличимы друг от друга)

- $T_{i,m}$ и $T_{j,m}$ тривиально совпадают, если $|i - j| < \lceil \xi m \rceil$
- Коэф. исключения $0 < \xi \leq 1$ – параметр, обычно $\xi = 0.5$

Содержание

- Объект и предмет дисциплины
- Ключевые особенности интеллектуальной обработки временных рядов
- Основные задачи интеллектуального анализа временных рядов
- **Определения и нотация**
  - Временной ряд и подпоследовательность
  - Функции расстояния
  - Тривиальные совпадения
  - Ближайший сосед

Ближайший сосед (Nearest Neighbor)

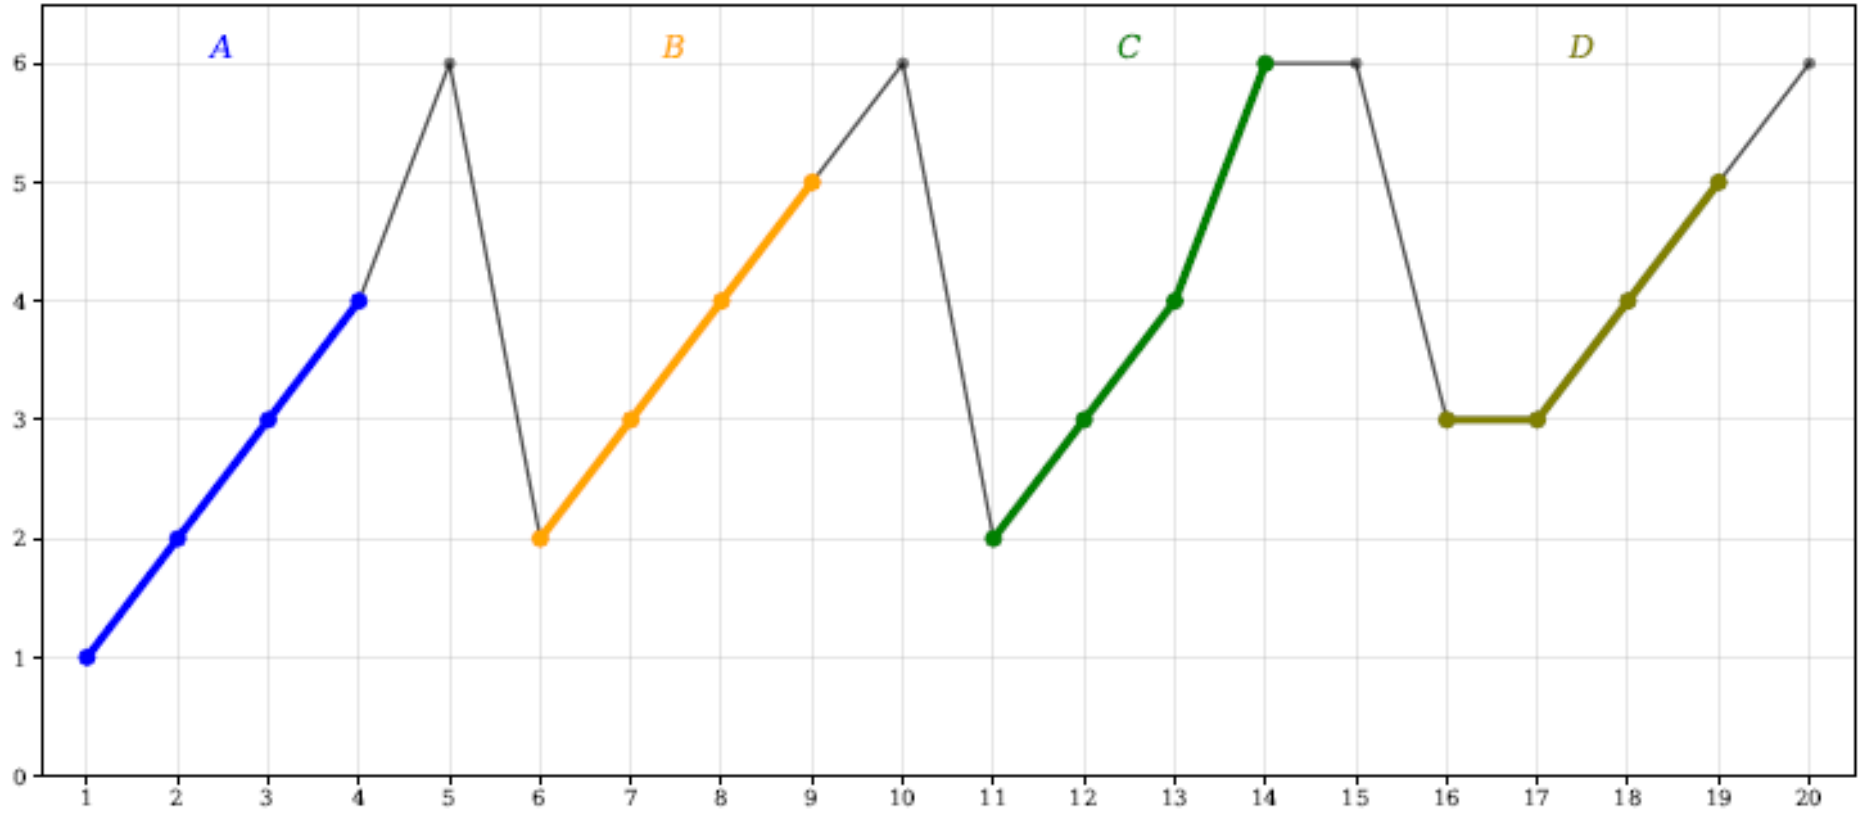
- *(1-й) ближайший сосед* данной подпоследовательности-запроса – подпоследовательность ряда, которая наиболее похожа на нее и не является ее тривиальным совпадением

$$\theta_{1\mathrm{NN}}(Q, N) = \mathrm{TRUE} \Leftrightarrow N = \arg\min_{C \in \mathcal{N}_Q} \mathrm{Dist}(Q, C),$$

где $\mathcal{N}_Q$ – подпоследовательности, **НЕ** явл. трив. совпадениями Q

- Поиск ближайших соседей необходим в практически любой задаче интеллектуального анализа временных рядов
  - поиск по образцу = поиск ближайшего соседа
  - поиск мотивов = поиск пары ближайших соседей с min расстоянием
  - и т.д.

Функция $\theta_{1\mathrm{NN}}(\cdot,\cdot)$ не симметрична



$\mathrm{ED}(\cdot,\cdot)$	A	B	C	D
A	0	2.000	2.646	2.646
B	2.000	0	1.000	1.000
C	2.646	1.000	0	1.414
D	2.646	1.000	1.414	0

$\theta_{1\mathrm{NN}}(\cdot,\cdot)$	A	B	C	D
A	FALSE	TRUE	FALSE	FALSE
B	FALSE	FALSE	TRUE	TRUE
C	FALSE	TRUE	FALSE	FALSE
D	FALSE	TRUE	FALSE	FALSE

Потоковый временной ряд (streaming time series)

- Бесконечная упорядоченная последовательность вещественных значений, которые поступают непрерывно одно за другим в режиме реального времени

$$T = (t_1, \dots, t_n, \dots), \ t_i \in \mathbb{R}$$

альтернативная запись: $T = \{t_i\}_{i=1}^{\infty}$

- Режим реального времени предполагает конечный период времени обработки данных для *конкретной предметной области*:
реальное время ≠ «очень быстро»

Литература

Цымблер М.Л. Интеллектуальный анализ временных рядов: учебное пособие. Челябинск: Издательский центр ЮУрГУ, 2026. 295 с. (в печати)

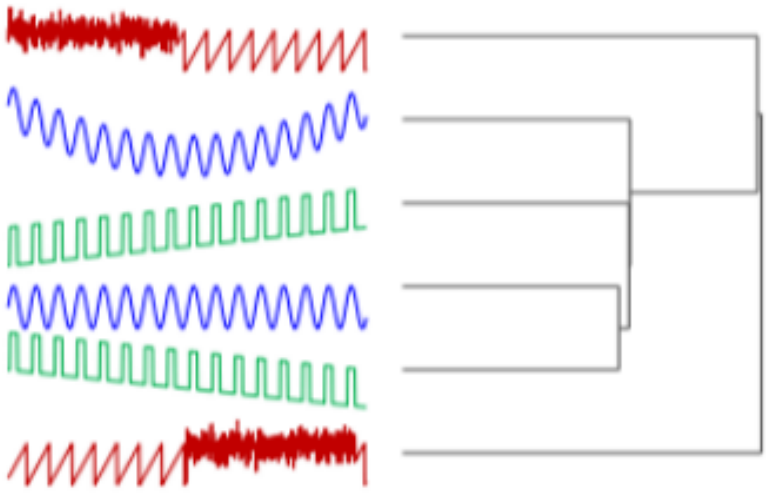
Глава 1. Базовые понятия и определения

https://mzym.susu.ru/courses/tsm/tsmbook.pdf

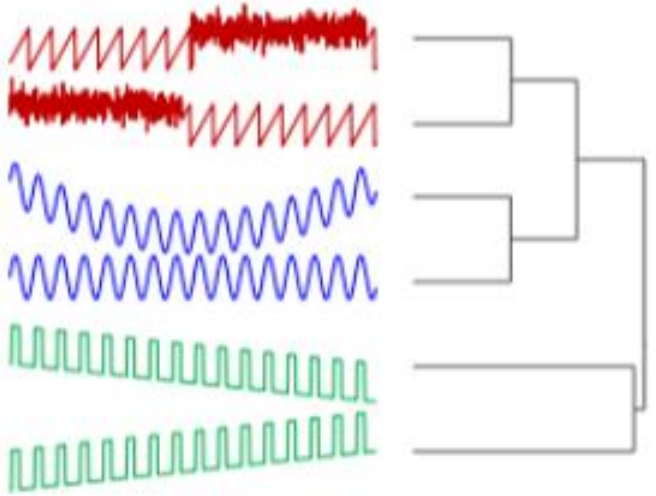
Классификация и кластеризация временных рядов

- При небольшой длине рядов можно использовать стандартные алгоритмы машинного обучения и адекватные функции для вычисления схожести (например, Dynamic Time Warping)
- Для длинных временных рядов нужны специализированные функции для вычисления схожести

DTW



PRCIS
(Pattern Representation Comparison in Series)*



* Der A. *et al.* Matrix Profile XXVII: A Novel Distance Measure for Comparing Long Time Series. ICKG 2022. P. 40-47. https://doi.org/10.1109/ICKG55886.2022.00013

Классификация подпоследовательностей ряда возможна, но их кластеризация БЕССМЫСЛЕННА*

- Подпоследовательности одного временного ряда обычно сильно коррелируют между собой, что делает их неинформативными для кластеризации
- Подпоследовательности разных временных рядов обычно имеют различные характеристики и паттерны, что позволяет выделить более информативные признаки и получить осмысленный результат кластеризации
- Пример: мониторинг температуры в помещении
  - Если температура в помещении измеряется каждые 5 мин., то подпоследовательности измерений за последний час будут сильно коррелировать между собой, так как температура в помещении обычно меняется медленно и плавно
  - Кластеризация подпоследовательностей измерений за последний час не будет иметь смысла, так как они будут очень похожи друг на друга и не будут содержать достаточно информации для кластеризации
  - Для кластеризации нужно использовать подпоследовательности измерений за разные периоды времени (за последние сутки, неделю, месяц и др.)

* Keogh E., Lin J. Clustering of time-series subsequences is meaningless: implications for previous and future research. Knowl. Inf. Syst. 8(2). 2005. 154-177. DOI: 10.1007/s10115-004-0172-7